Relációs algebrai optimalizálás

- A lekérdezések optimalizálásának folyamata
- Az algebrai optimalizálás szerepe, célja
- 11 ekvivalencia szabálytípus
- Az algebrai optimalizálás heurisztikus megadása
- Az algoritmus formálisan
- Példa

Lekérdezések optimalizálása

CÉL: A lekérdezéseket gyorsabbá akarjuk tenni a táblákra vonatkozó paraméterek, statisztikák, indexek ismeretében
és általános érvényű tulajdonságok, heurisztikák segítségével.

Például, hogyan, milyen procedúrával értékeljük ki az alábbi SQL (deklaratív) lekérdezést?

Legyen adott R(A,B,C) és S(C,D,E). Melyek azok az R.B és S.D értékek azokban az R, illetve S táblabeli sorokban, amely sorokban R.A='c' és S.E=2 és R.C=S.C?

Ugyanez SQL-ben:

```
Select B,D
From R,S
Where R.A = 'c' and S.E = 2 and R.C=S.C;
```

Lekérdezések optimalizálása

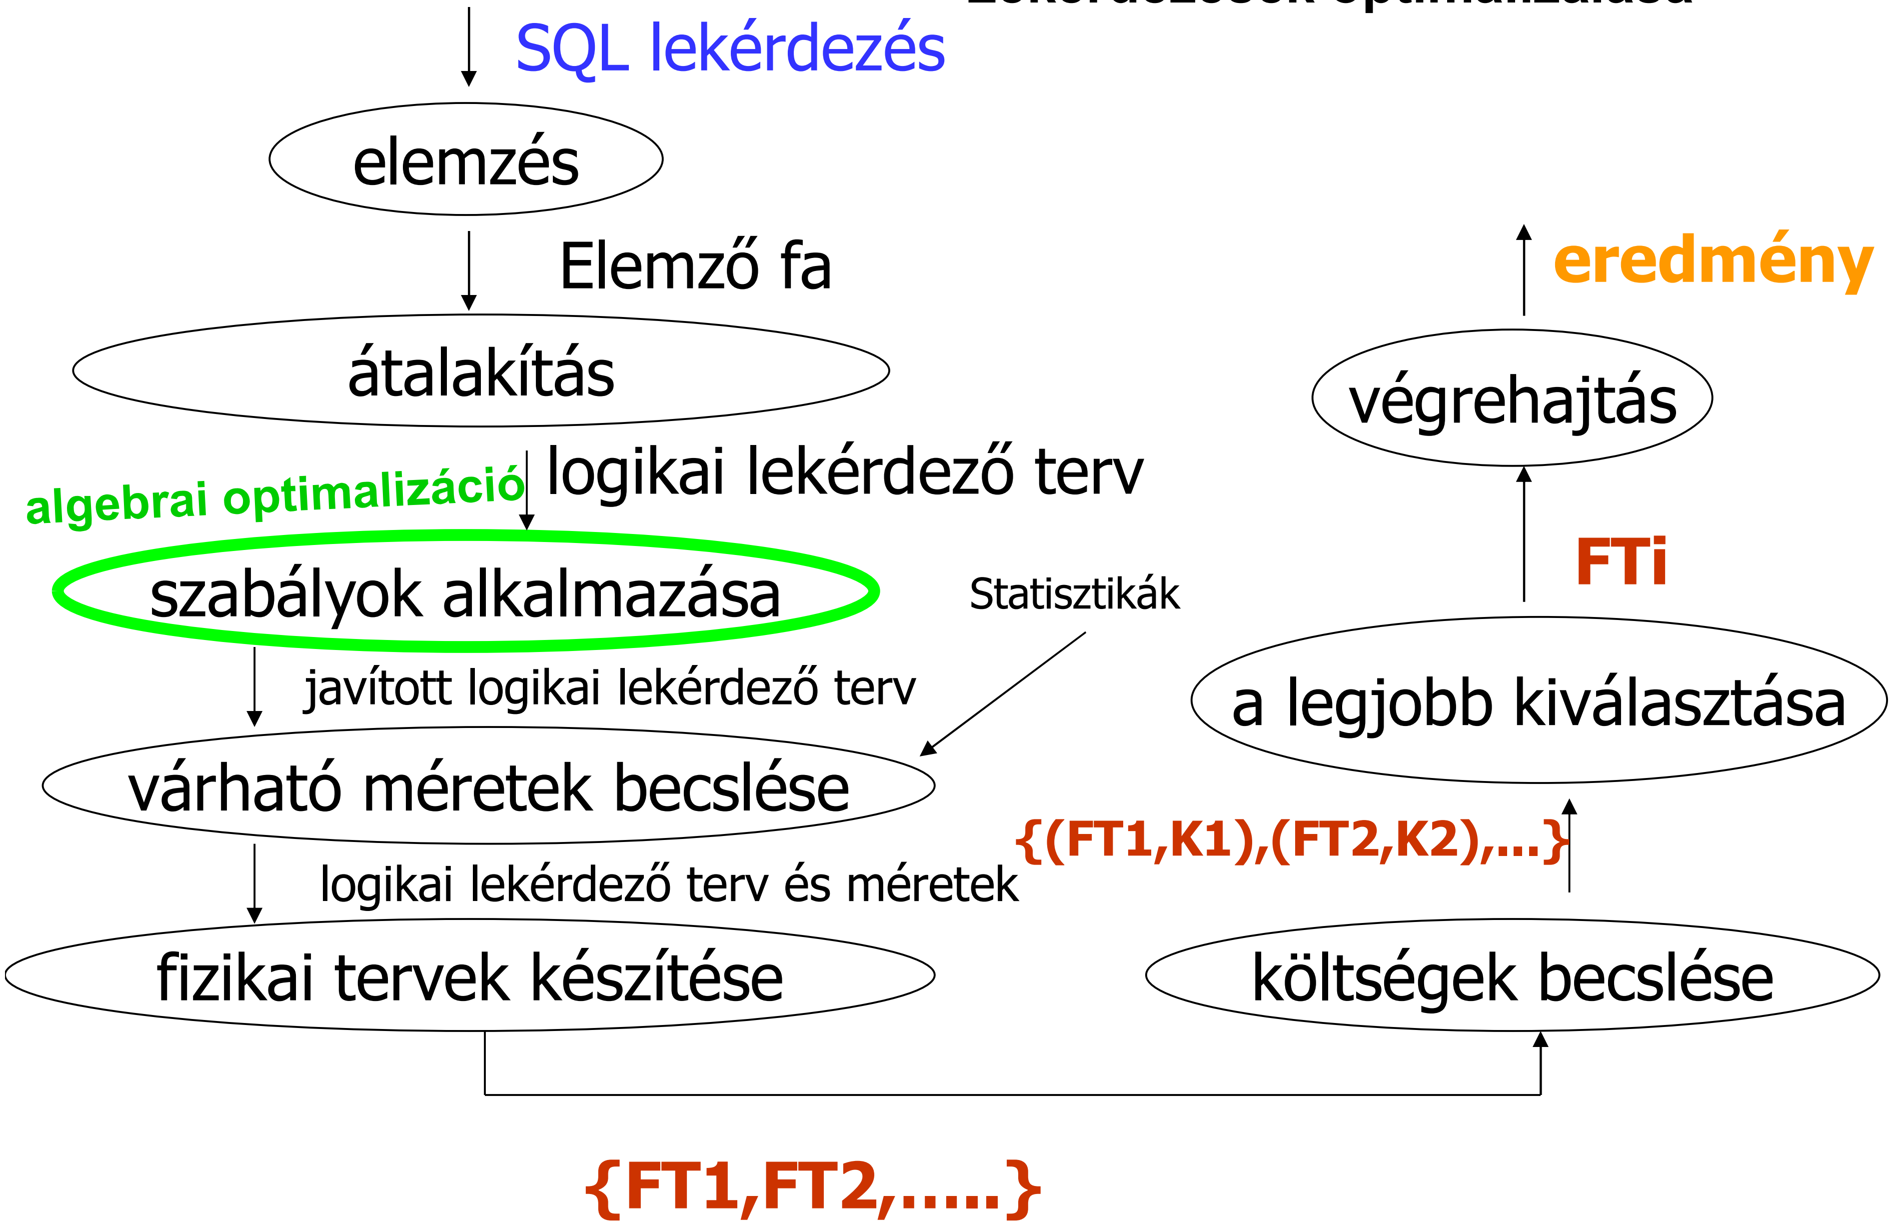

Lekérdezések optimalizálása

R

A	B	C
a	1	10
b	1	20
c	2	10
d	2	35
e	3	45

S

C	D	E
10	x	2
20	y	2
30	z	2
40	x	1
50	y	3

A lekérdezés eredménye:

B	D
2	x

Select B,D From R,S
Where R.A = 'c' and
S.E = 2 and
R.C=S.C;

Lekérdezések optimalizálása

Hogy számoljuk ki tetszőleges tábla esetén az eredményt?

Egy lehetséges terv

- Vegyük a két tábla szorzatát!
- Válasszuk ki a megfelelő sorokat!
- Hajtsuk végre a vetítést!

$$\Pi_{B,D}\,[\,\sigma_{R.A='c' \wedge S.E=2 \wedge R.C = S.C}\,(R X S)]$$

- Ez a direktszorzaton alapuló összekapcsolás.
- Oracleben: NESTED LOOP.
- Nagyon költséges!

RXS

R.A	R.B	R.C	S.C	S.D	S.E
a	1	10	10	x	2
a	1	10	20	y	2
.					
.					
c	2	10	10	x	2
.					
.					

Ez a sor kell!

B	D
2	x

$\Pi_{B,D}\,[\,\sigma_{R.A='c' \wedge S.E=2 \wedge R.C = S.C}\,(RXS)]$

Lekérdezések optimalizálása

Ugyanez a terv relációs algebrában:

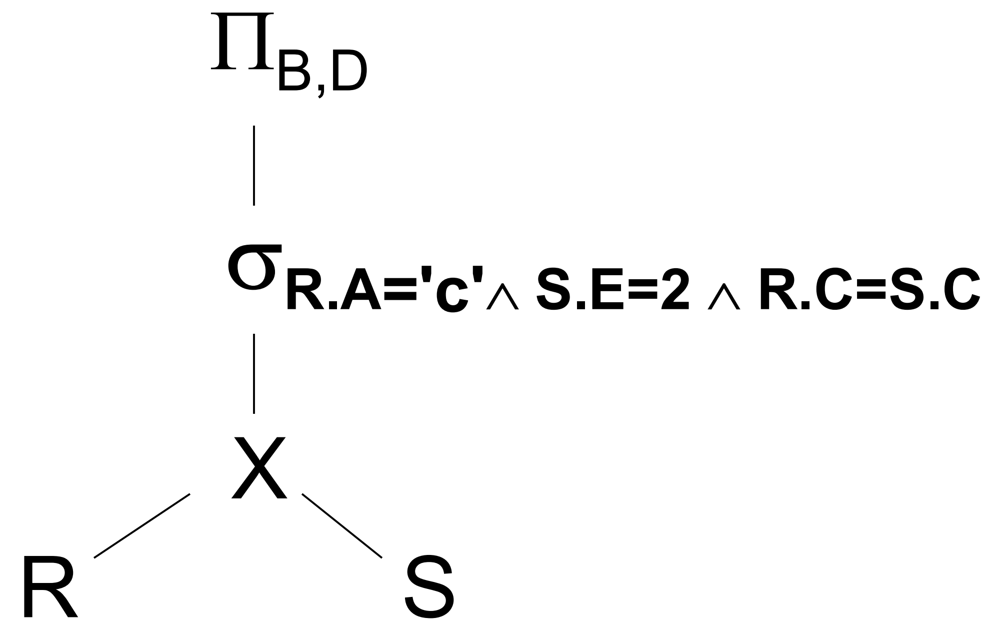

$$\Pi_{B,D} [\sigma_{R.A='c' \wedge S.E=2 \wedge R.C = S.C} (RXS)]$$

Lekérdezések optimalizálása

R

A	B	C
a	1	10
b	1	20
c	2	10
d	2	35
e	3	45

σ (R)

A	B	C
c	2	10

σ(S)

C	D	E
10	x	2
20	y	2
30	z	2

S

C	D	E
10	x	2
20	y	2
30	z	2
40	x	1
50	y	3

$\bowtie$

$\Pi_{B,D}$

Ugyanazt számolja ki!

B	D
2	x

Lekérdezések optimalizálása

Egy másik lehetséges kiszámítási javaslat:

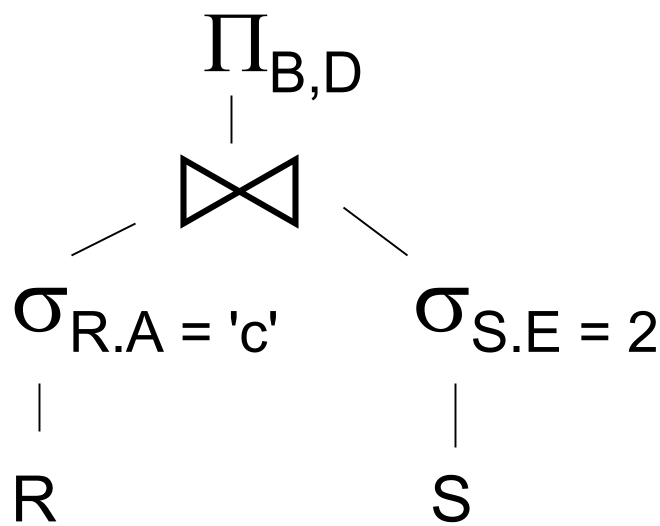

$$\Pi_{B,D}\,[\,\sigma_{R.A='c' \wedge S.E=2 \wedge R.C = S.C}\,(RXS)]$$

helyett

$$\Pi_{B,D}\,[\,\sigma_{R.A='c'}\,(R) \bowtie \sigma_{S.E=2}\,(S)]$$

Lekérdezések optimalizálása

Használjuk ki az R.A és S.C oszlopokra készített **indexeket**:

(1) Az R.A index alapján keressük meg az R azon sorait, amelyekre R.A = 'c'!

(2) Minden megtalált R.C értékhez az S.C index alapján keressük meg az S-ből az ilyen értékű sorokat!

(3) Válasszuk ki a kapott S-beli sorok közül azokat, amelyekre S.E = 2!

(4) Kapcsoljuk össze az R és S így kapott sorait, és végül vetítsünk a B és D oszlopokra.

R

A	B	C
a	1	10
b	1	20
c	2	10
d	2	35
e	3	45

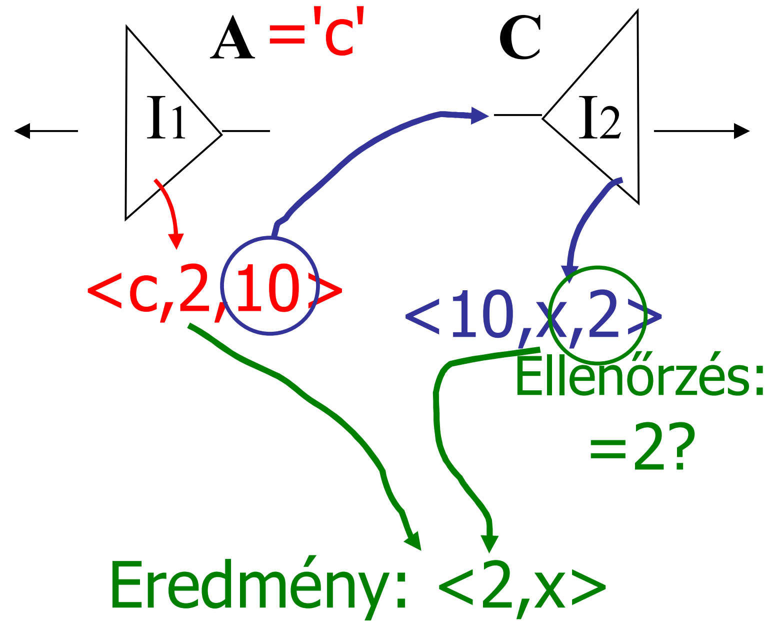

S

C	D	E
10	x	2
20	y	2
30	z	2
40	x	1
50	y	3

INDEXES ÖSSZEKAPCSOLÁS

Példa: SQL lekérdezés

```
SELECT title
FROM StarsIn
WHERE starName IN (
        SELECT name
        FROM MovieStar
        WHERE birthdate LIKE ‘%1960’
);
```

Milyen filmekben szerepeltek 1960-as születésű színészek?

Elemzőfa: Parse Tree

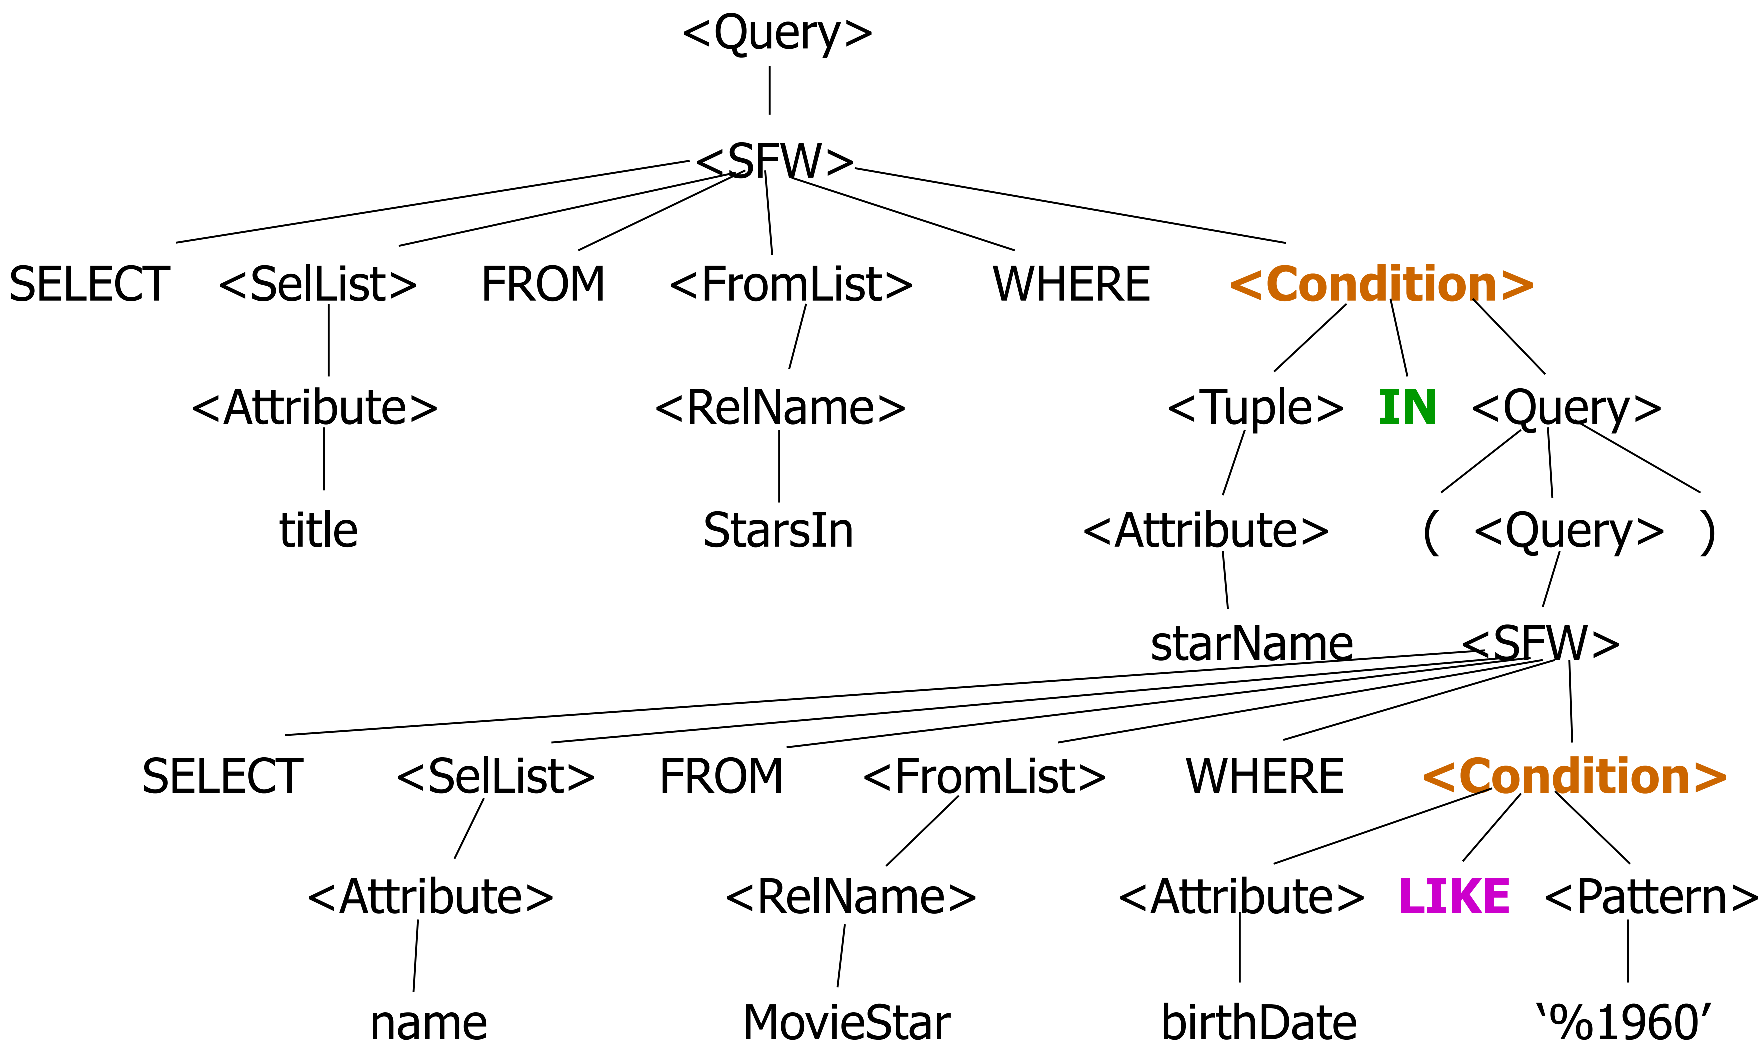

Ugyanez relációs algebrában:

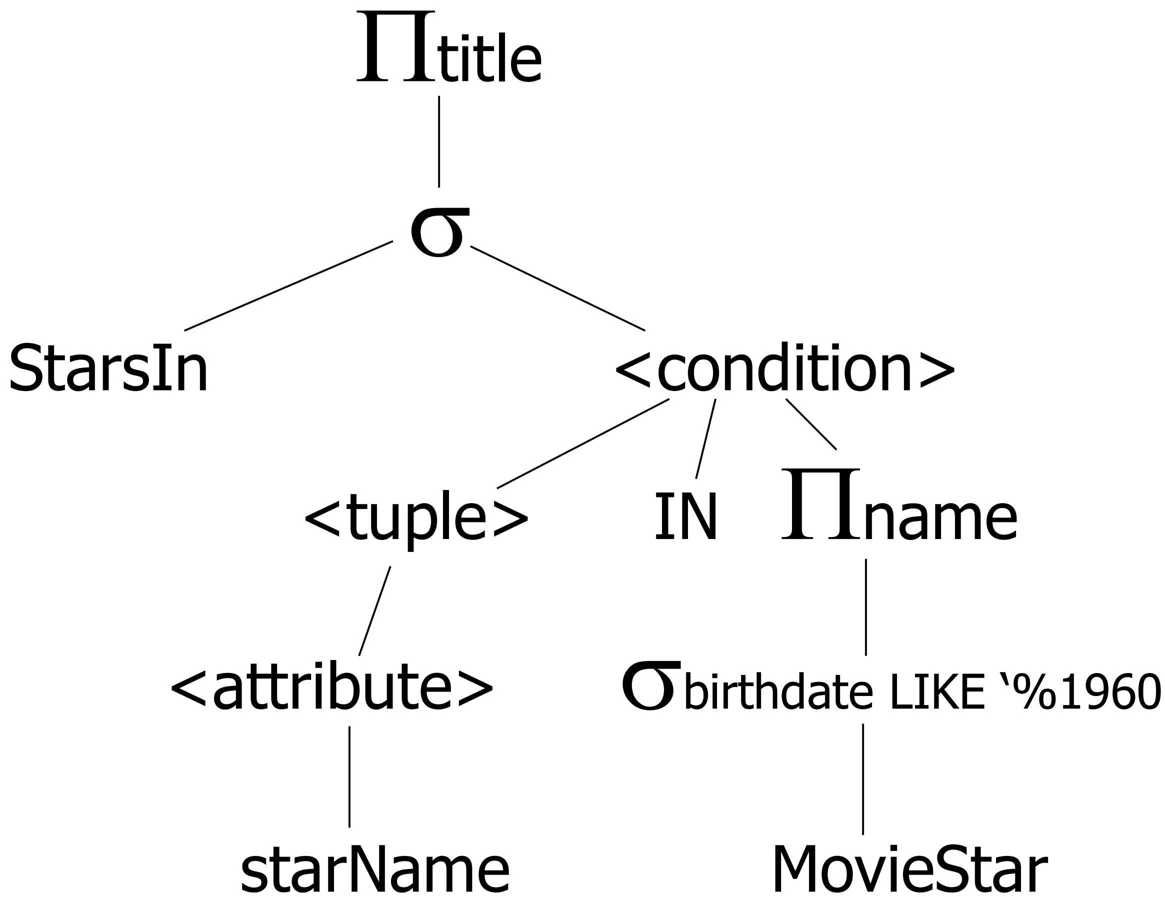

Átalakított logikai lekérdező terv

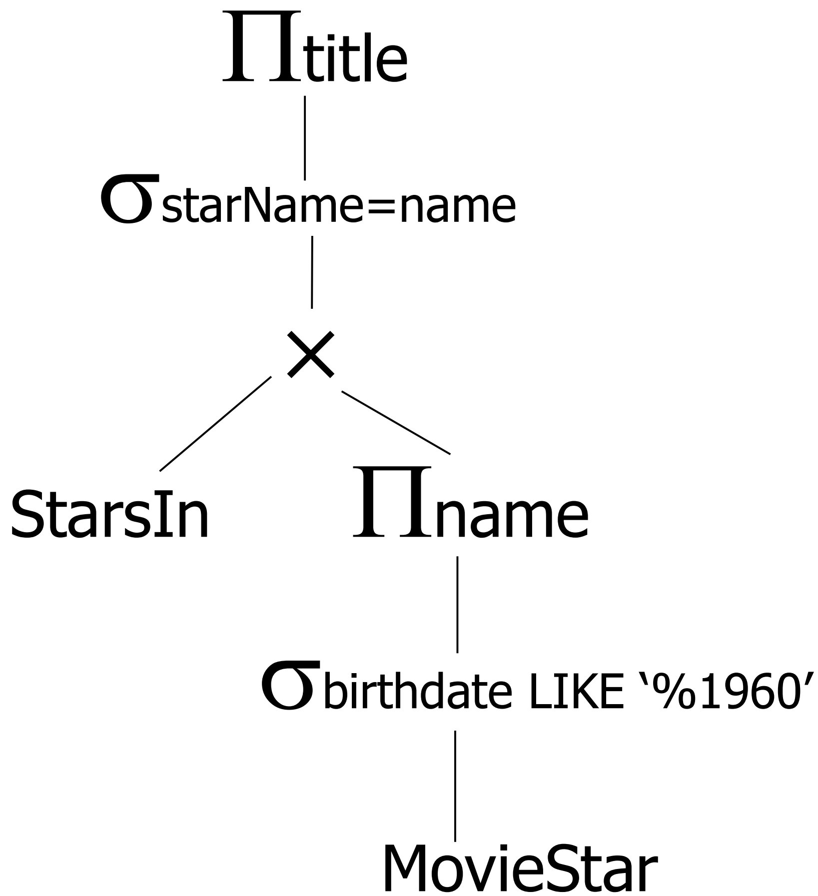

Továbbjavított logika lekérdező terv

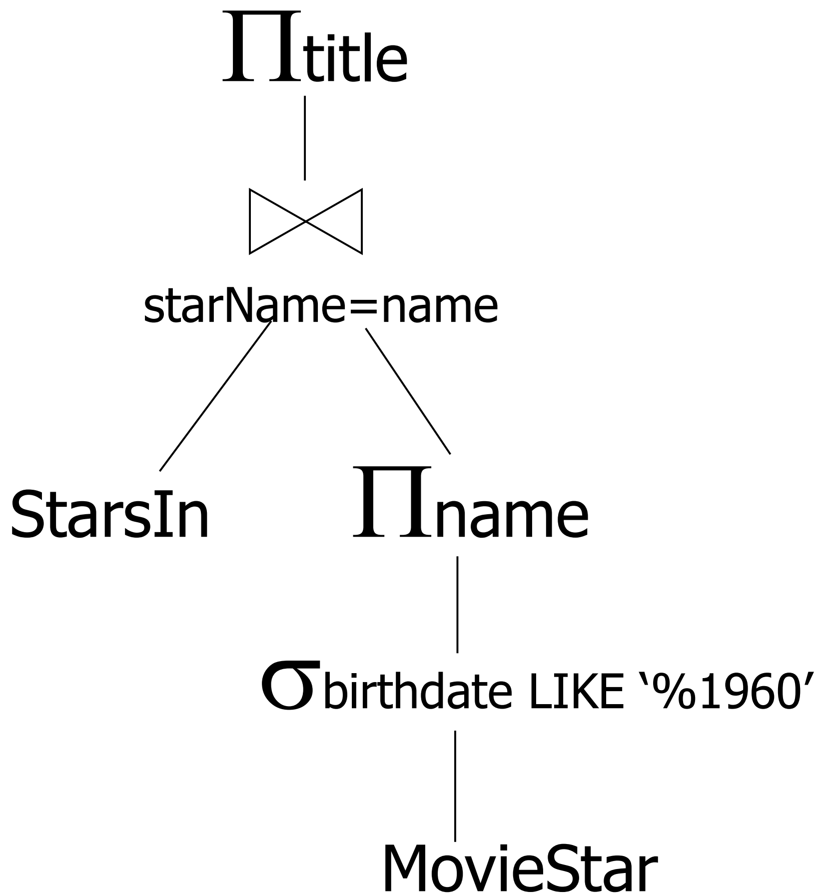

Algebrai optimalizáció

- **Cél:** a relációs algebrai kifejezéseket minél gyorsabban akarjuk kiszámolni.
- **Költségmodell:** a kiszámítás költsége arányos a relációs algebrai kifejezés részkifejezéseinek megfelelő relációk tárolási méreteinek összegével.
- **Módszer:** a műveleti tulajdonságokon alapuló ekvivalens átalakításokat alkalmazunk, hogy várhatóan kisebb méretű relációk keletkezzenek.
- **Az eljárás heurisztikus**, tehát nem az argumentum relációk valódi méretével számol.
- **Az eredmény nem egyértelmű:** Az átalakítások sorrendje nem determinisztikus, így más sorrendben végrehajtva az átalakításokat más végeredményt kaphatunk, de mindegyik általában jobb költségű, mint amiből kiindultunk.
- **Megjegyzés:** Mivel az SQL bővebb, mint a relációs algebra, ezért az optimalizálást bővített relációs algebrára is meg kell adni, de először a hagyományos algebrai kifejezéseket vizsgáljuk.

Algebrai optimalizáció

- A relációs algebrai kifejezést **gráffal** ábrázoljuk.
- **Kifejezésfa:**
  – a **nem levél csúcsok**: a relációs algebrai műveletek:
    - unáris (σ,Π,ρ) – egy gyereke van
    - bináris (-,$\cup$,$\times$) – két gyereke van (bal oldali az első, jobb oldali a második argumentumnak felel meg)

  – a **levél csúcsok**: konstans relációk vagy relációs változók

Algebrai optimalizáció

- könyv(sorszám,író,könyvcím)
  - **kv(s,i,kc)**
- kölcsönző(azonosító,név,lakcím)
  - **kő(a,n,lc)**
- kölcsönzés(sorszám,azonosító,dátum)
  - **ks(s,a,d)**
- Milyen című könyveket kölcsönöztek ki 2007-től kezdve?
- $\Pi_{\mathbf{kc}}(\sigma_{\mathbf{d>='2007.01.01'}}(\mathbf{kv}|\times|\mathbf{kő}|\times|\mathbf{ks}))$
- Az összekapcsolásokat valamilyen sorrendben kifejezzük az alapműveletekkel:

$$\Pi_{\mathbf{kc}}(\sigma_{\mathbf{d>='2007.01.01'}}(\Pi_{\mathbf{kv.s,i,kc,kő.a,n,lc,d}}(\sigma_{\mathbf{kv.s=ks.s} \wedge \mathbf{kő.a=ks.a}}(\mathbf{kv}\times(\mathbf{kő}\times\mathbf{ks})))))$$

Algebrai optimalizáció

$$\Pi_{kc}(\sigma_{d>='2007.01.01'}(\Pi_{kv.s,i,kc,kő.a,n,lc,d}(\sigma_{kv.s=ks.s \wedge kő.a=ks.a}(kv\times(kő\times ks)))))$$

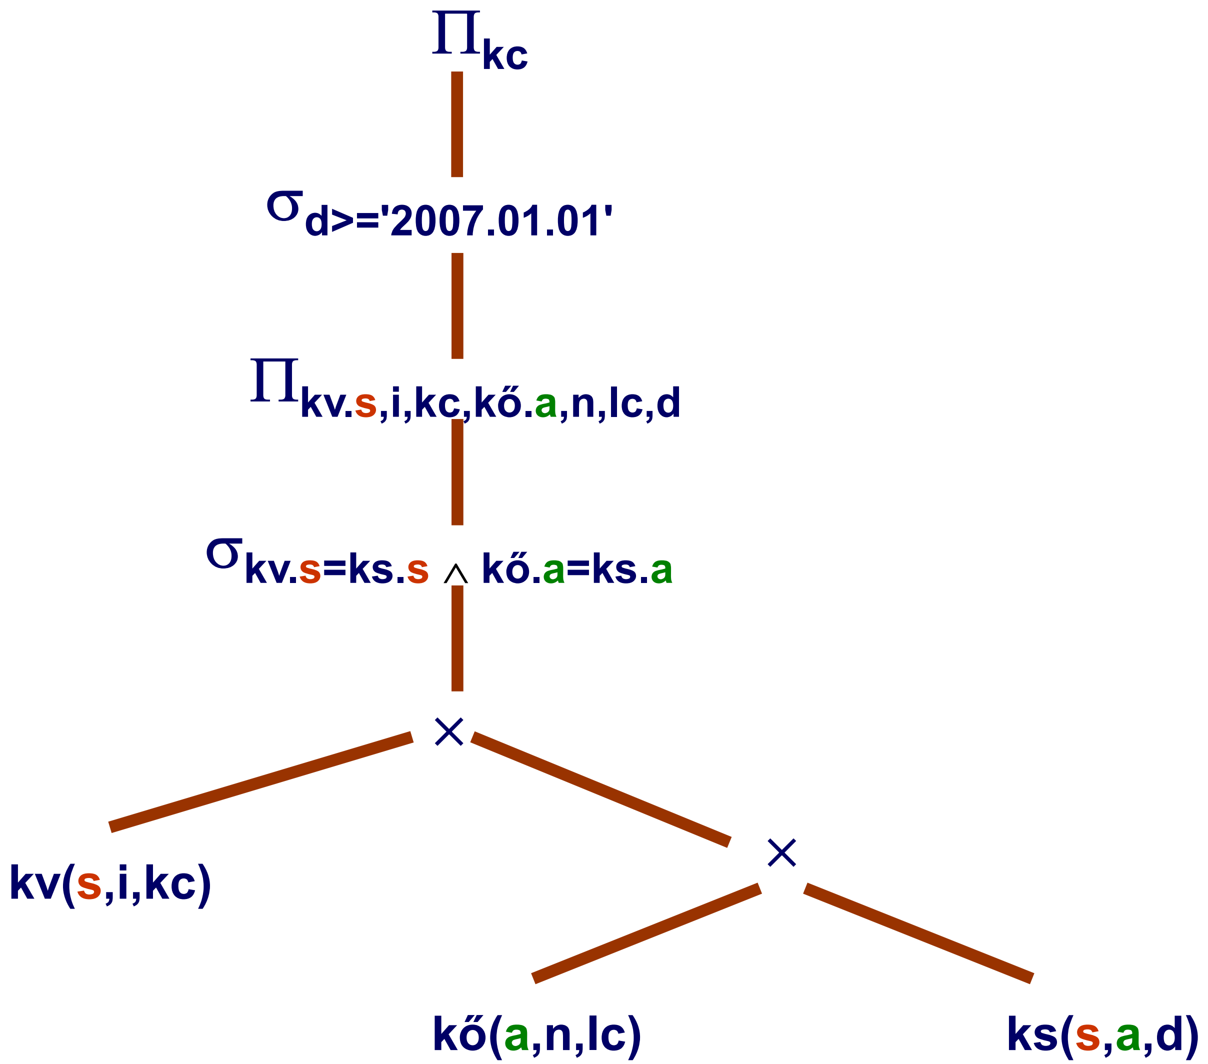

Algebrai optimalizáció

- $E1(r1,...,rk)$ és $E2(r1,...,rk)$ **relációs algebrai kifejezések ekvivalensek** ($E1 \cong E2$), ha tetszőleges r1,...,rk relációkat véve $E1(r1,...,rk)=E2(r1,...,rk)$.
- 11 szabályt adunk meg. A szabályok olyan állítások, amelyek kifejezések ekvivalenciáját fogalmazzák meg. Bizonyításuk könnyen végiggondolható.
- Az állítások egy részében a kifejezések szintaktikus helyessége egyben elégséges feltétele is az ekvivalenciának.

1. **Kommutativitás (szorzás, természetes összekapcsolás, téta-összekapcsolás)**
   - $\mathbf{E1 \times E2 \cong E2 \times E1}$
   - $\mathbf{E1\ |\times|\ E2 \cong E2\ |\times|\ E1}$
   - $\mathbf{E1\ \underset{\Theta}{|\times|}\ E2 \cong E2\ \underset{\Theta}{|\times|}\ E1}$

Algebrai optimalizáció

2. **Asszociativitás (szorzás, természetes összekapcsolás, téta-összekapcsolás)**
   - $(E1 \times E2) \times E3 \cong E1 \times (E2 \times E3)$
   - $(E1 \mid\!\times\!\mid E2) \mid\!\times\!\mid E3 \cong E1 \mid\!\times\!\mid (E2 \mid\!\times\!\mid E3)$
   - $(E1 \underset{\Theta}{\mid\!\times\!\mid} E2) \underset{\Theta}{\mid\!\times\!\mid} E3 \cong E1 \underset{\Theta}{\mid\!\times\!\mid} (E2 \underset{\Theta}{\mid\!\times\!\mid} E3)$
3. **Vetítések összevonása, bővítése**
   - Legyen $\underline{A}$ és $\underline{B}$ két részhalmaza az E reláció oszlopainak úgy, hogy $\underline{\mathbf{A}} \subseteq \underline{\mathbf{B}}$.
   - Ekkor $\Pi_{\underline{A}}(\Pi_{\underline{B}}(E)) \cong \Pi_{\underline{A}}(E)$.
4. **Kiválasztások felcserélhetősége, felbontása**
   - Legyen F1 és F2 az E reláció oszlopain értelmezett kiválasztási feltétel.
   - Ekkor $\sigma_{F1 \wedge F2}(E) \cong \sigma_{F1}(\sigma_{F2}(E)) \cong \sigma_{F2}(\sigma_{F1}(E))$.

Algebrai optimalizáció

5. **Kiválasztás és vetítés felcserélhetősége**

- Legyen F az E relációnak csak az $\underline{A}$ oszlopain értelmezett kiválasztási feltétel.

a) • Ekkor $\Pi_{\underline{A}}(\sigma_F(E)) \cong \sigma_F(\Pi_{\underline{A}}(E))$.

- Általánosabban: Legyen F az E relációnak csak az $\underline{\mathbf{A}} \cup \underline{\mathbf{B}}$ oszlopain értelmezett kiválasztási feltétel, ahol $\underline{\mathbf{A}} \cap \underline{\mathbf{B}} = \emptyset$.

b) • Ekkor $\Pi_{\underline{A}}(\sigma_F(E)) \cong \Pi_{\underline{A}}(\sigma_F(\Pi_{\underline{A} \cup \underline{B}}(E)))$.

6. **Kiválasztás és szorzás felcserélhetősége**

- Legyen F az E1 reláció oszlopainak egy részhalmazán értelmezett kiválasztási feltétel.

a) • Ekkor $\sigma_F(E1 \times E2) \cong \sigma_F(E1) \times E2$.

- Speciálisan: Legyen i=1,2 esetén Fi az Ei reláció oszlopainak egy részhalmazán értelmezett kiválasztási feltétel, legyen továbbá $F = F1 \wedge F2$.

b) • Ekkor $\sigma_F(E1 \times E2) \cong \sigma_{F1}(E1) \times \sigma_{F2}(E2)$.

- Általánosabban: Legyen F1 az E1 reláció oszlopainak egy részhalmazán értelmezett kiválasztási feltétel, legyen F2 az $E1 \times E2$ reláció oszlopainak egy részhalmazán értelmezett kiválasztási feltétel, úgy hogy mindkét sémából legalább egy oszlop szerepel benne, legyen továbbá $F = F1 \wedge F2$.

c) • Ekkor $\sigma_F(E1 \times E2) \cong \sigma_{F2}(\sigma_{F1}(E1) \times E2)$.

Algebrai optimalizáció

7. **Kiválasztás és egyesítés felcserélhetősége**
   - Legyen E1, E2 relációk sémája megegyező, és F a közös sémán értelmezett kiválasztási feltétel.
   - Ekkor $\sigma_F(\mathbf{E1} \cup \mathbf{E2}) \cong \sigma_F(\mathbf{E1}) \cup \sigma_F(\mathbf{E2})$.
8. **Kiválasztás és kivonás felcserélhetősége**
   - Legyen E1, E2 relációk sémája megegyező, és F a közös sémán értelmezett kiválasztási feltétel.
   - Ekkor $\sigma_F(\mathbf{E1} - \mathbf{E2}) \cong \sigma_F(\mathbf{E1}) - \sigma_F(\mathbf{E2})$.
9. **Kiválasztás és természetes összekapcsolás felcserélhetősége**
   - Legyen F az E1 és E2 közös oszlopainak egy részhalmazán értelmezett kiválasztási feltétel.
   - Ekkor $\sigma_F(\mathbf{E1} |\times| \mathbf{E2}) \cong \sigma_F(\mathbf{E1}) |\times| \sigma_F(\mathbf{E2})$.

Algebrai optimalizáció

10. Vetítés és szorzás felcserélhetősége

- Legyen i=1,2 esetén $\underline{Ai}$ az Ei reláció oszlopainak egy halmaza, valamint legyen $\underline{A}=\underline{A1}\cup\underline{A2}$.
- Ekkor $\Pi_{\underline{A}}(\mathbf{E1}\times\mathbf{E2}) \cong \Pi_{\underline{A1}}(\mathbf{E1})\times\Pi_{\underline{A2}}(\mathbf{E2})$.

11. Vetítés és egyesítés felcserélhetősége

- Legyen E1 és E2 relációk sémája megegyező, és legyen $\underline{A}$ a sémában szereplő oszlopok egy részhalmaza.
- Ekkor $\Pi_{\underline{A}}(\mathbf{E1}\cup\mathbf{E2}) \cong \Pi_{\underline{A}}(\mathbf{E1})\cup\Pi_{\underline{A}}(\mathbf{E2})$.

- Megjegyzés: A vetítés és kivonás nem cserélhető fel, azaz $\Pi_{\underline{A}}(\mathbf{E1 - E2}) \cancel{\cong} \Pi_{\underline{A}}(\mathbf{E1}) - \Pi_{\underline{A}}(\mathbf{E2})$. Például:

E1:

A	B
0	0
0	1

E2:

A	B
0	0

esetén $\Pi_{\mathbf{A}}(\mathbf{E1 - E2})$:

A
0

míg

$\Pi_{\mathbf{A}}(\mathbf{E1}) - \Pi_{\mathbf{A}}(\mathbf{E2})=\varnothing$

Algebrai optimalizáció

- Az optimalizáló algoritmus a következő **heurisztikus elveken** alapul:

1. **Minél hamarabb szelektáljunk**, hogy a részkifejezések várhatóan kisebb relációk legyenek.
2. A szorzás utáni kiválasztásokból **próbáljunk természetes összekapcsolásokat képezni**, mert az összekapcsolás hatékonyabban kiszámolható, mint a szorzatból történő kiválasztás.
3. **Vonjuk össze az egymás utáni unáris műveleteket** (kiválasztásokat és vetítéseket), és ezekből lehetőleg egy kiválasztást, vagy vetítést, vagy kiválasztás utáni vetítést képezzünk. Így csökken a műveletek száma, és általában a kiválasztás kisebb relációt eredményez, mint a vetítés.
4. **Keressünk közös részkifejezéseket**, amiket így elég csak egyszer kiszámolni a kifejezés kiértékelése során.

Algebrai optimalizáció

- **Algebrai optimalizációs algoritmus:**
- INPUT: relációs algebrai kifejezés kifejezésfája
- OUTPUT: optimalizált kifejezésfa optimalizált kiértékelése

Hajtsuk végre az alábbi lépéseket a megadott sorrendben:

1. **A kiválasztásokat bontsuk fel** a **4. szabály** segítségével:
   - $\sigma_{F1\wedge\ldots\wedge Fn}(E) \cong \sigma_{F1}(\ldots(\sigma_{Fn}(E)))$
2. **A kiválasztásokat** a **4., 5., 6., 7., 8., 9. szabályok** segítségével **vigyük** olyan **mélyre** a kifejezésfában, amilyen mélyre csak lehet.
3. **A vetítéseket** a **3., 5., 10., 11. szabályok** segítségével **vigyük** olyan **mélyre** a kifejezésfában, amilyen mélyre csak lehet. Hagyjuk el a triviális vetítéseket, azaz az olyanokat, amelyek az argumentum reláció összes attribútumára vetítenek.
4. Ha egy relációs változóra vagy konstans relációra közvetlenül egymás után kiválasztásokat vagy vetítéseket alkalmazunk, akkor ezeket a **3., 4., 5. szabályok** segítségével **vonjuk össze egy kiválasztássá, vagy egy vetítéssé, vagy egy kiválasztás utáni vetítéssé, ha lehet** (azaz egy $\Pi.(\sigma.())$ alakú kifejezéssé). **Ezzel megkaptuk az optimalizált kifejezésfát.**
5. A gráfot **a bináris műveletek alapján bontsuk részgráfokra**. Minden részgráf egy bináris műveletnek feleljen meg. A részgráf csúcsai legyenek: a bináris műveletnek **($\cup$, —, $\times$)** megfelelő csúcs és a csúcs felett a következő bináris műveletig szereplő kiválasztások (σ) és vetítések (Π). Ha a bináris művelet szorzás ($\times$), és a részgráf equi-joinnak felel meg, és a szorzás valamelyik ága nem tartalmaz bináris műveletet, akkor ezt az ágat is vegyük hozzá a részgráfhoz.
6. Az előző lépésben kapott részgráfok is fát képeznek. **Az optimális kiértékeléshez** ezt a fát értékeljük ki alulról felfelé haladva, tetszőleges sorrendben.

Megjegyzés. Az **equi-join** azt jelenti, hogy a kiválasztás feltétele egyenlőség, amely a szorzás két ágának egy-egy oszlopát hasonlítja össze.

Algebrai optimalizáció

- Optimalizáljuk a következő kifejezést:

$$\Pi_{kc}(\sigma_{d>='2007.01.01'}(\Pi_{kv.s,i,kc,kő.a,n,lc,d}(\sigma_{kv.s=ks.s \wedge kő.a=ks.a}(kv\times(kő\times ks)))))$$

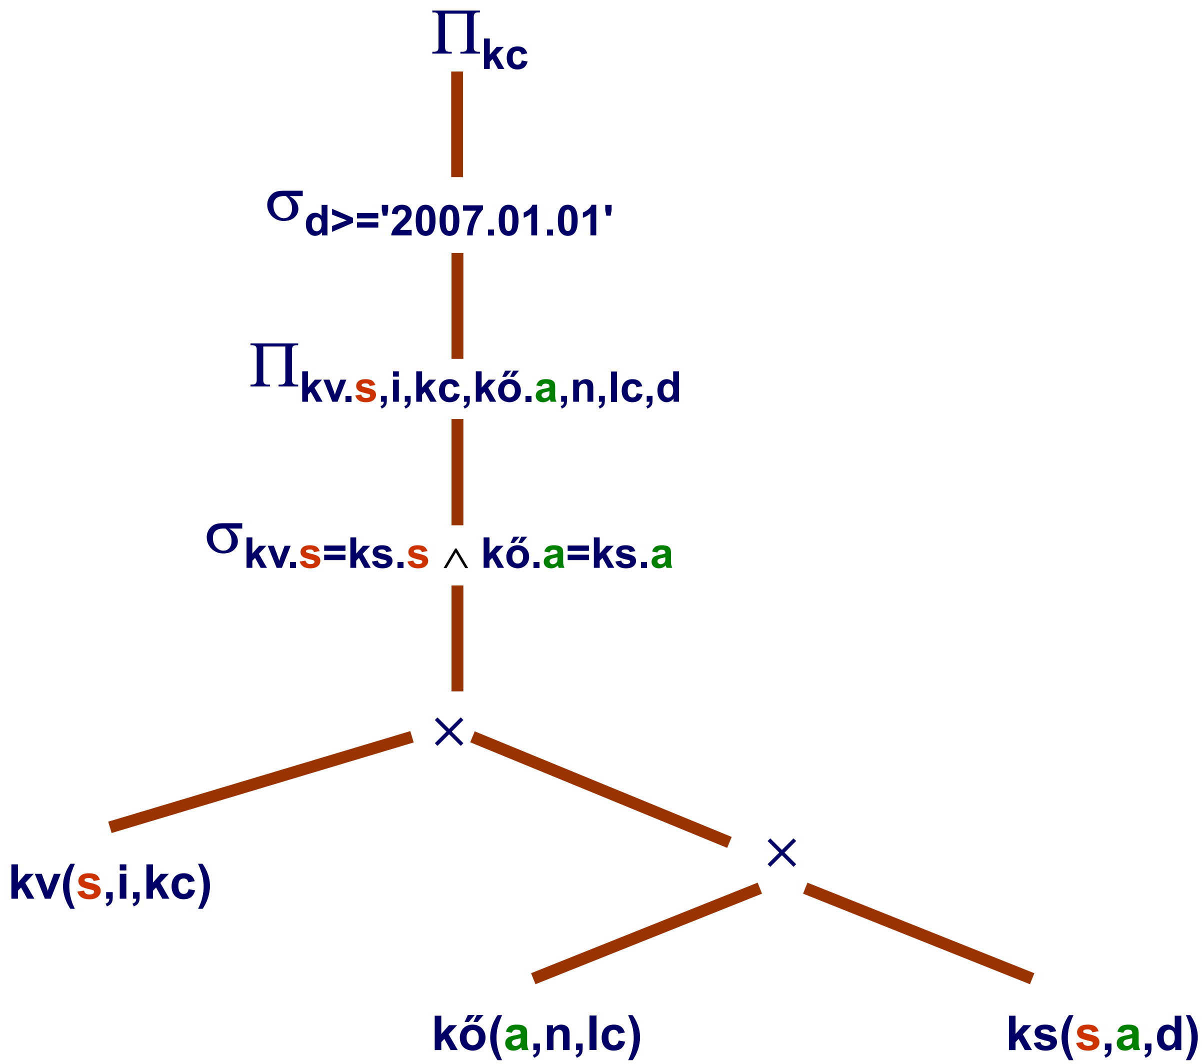

Algebrai optimalizáció

- **Kiválasztás felbontása:**

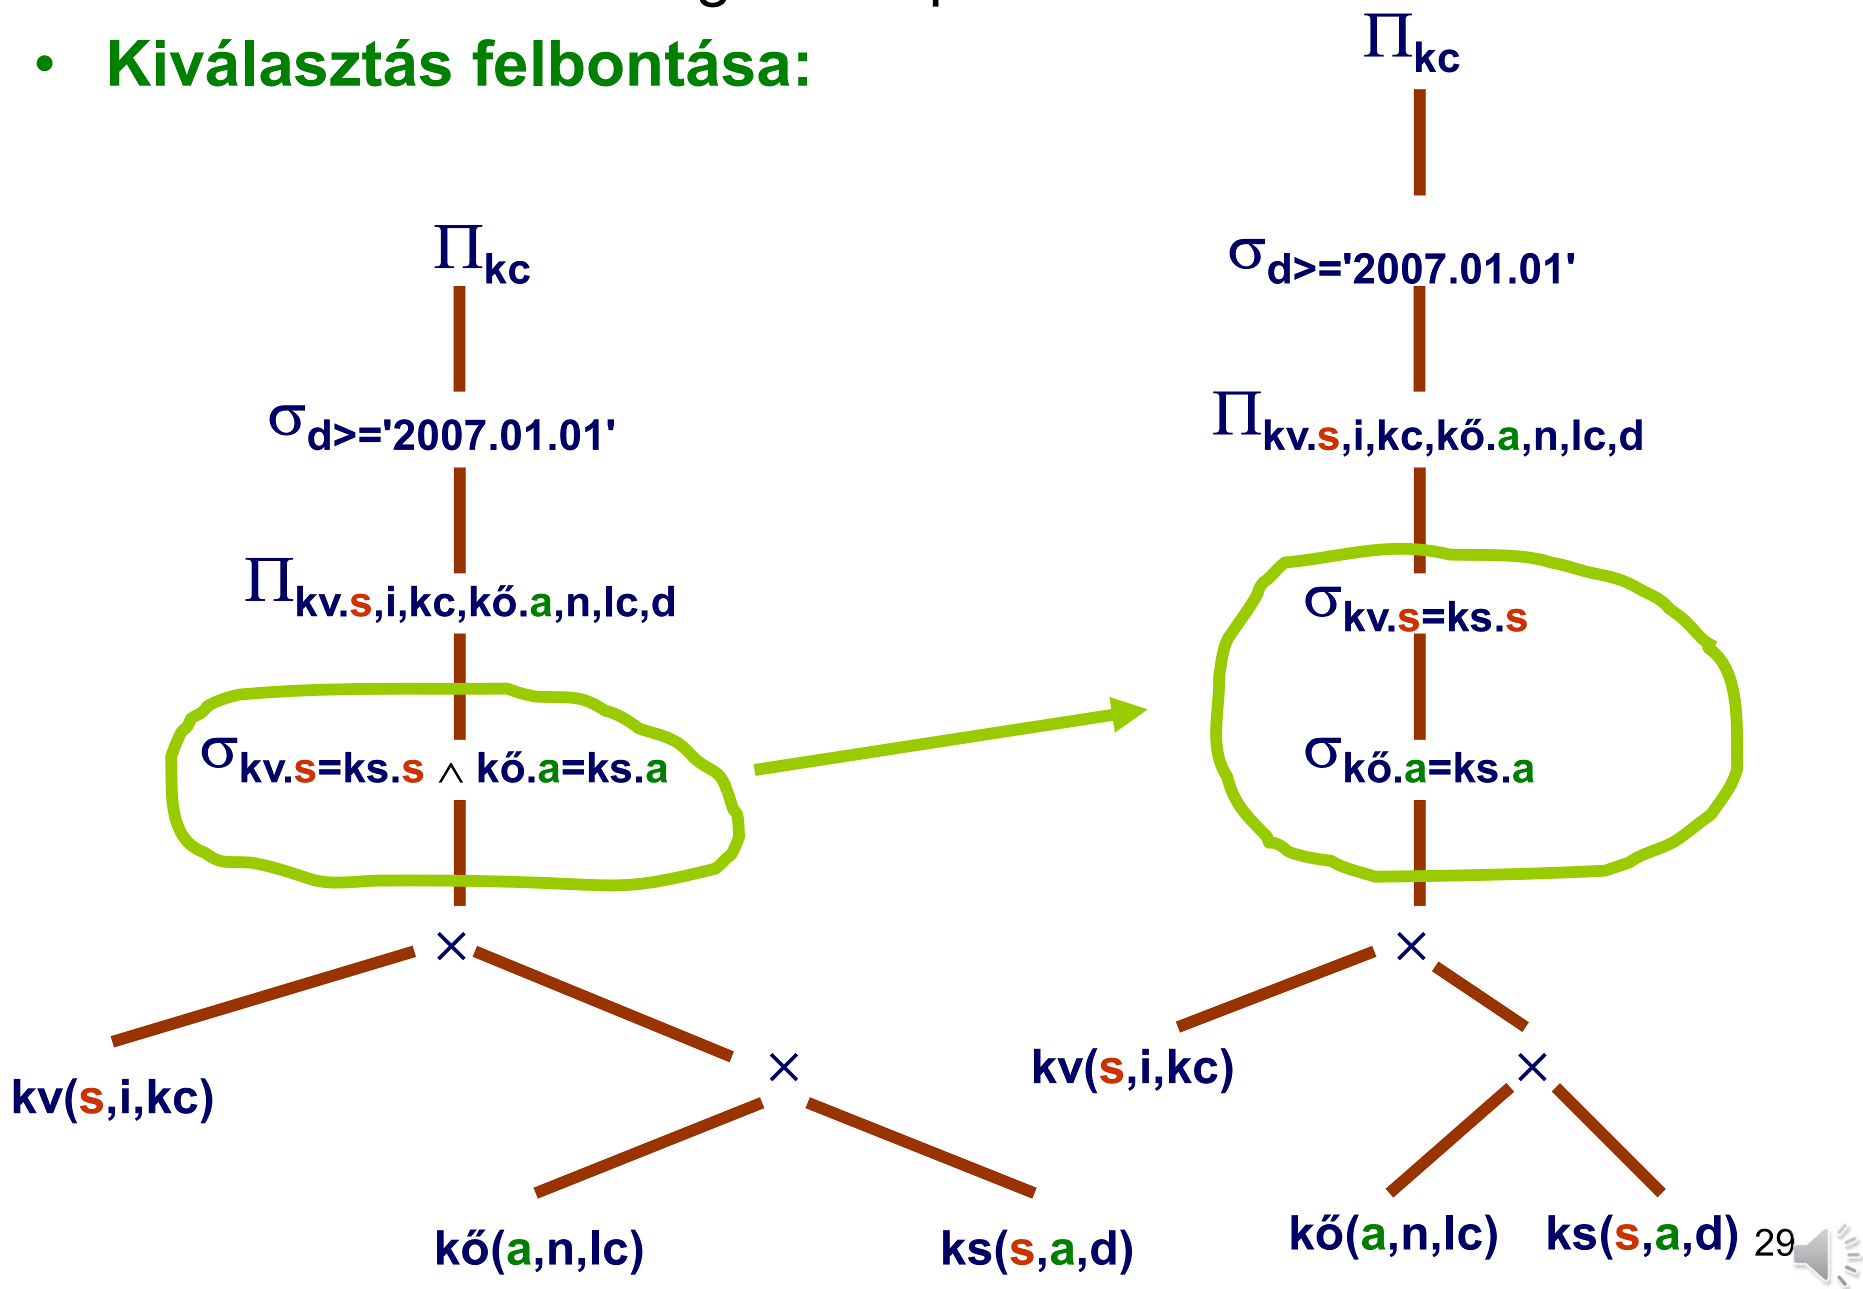

Algebrai optimalizáció

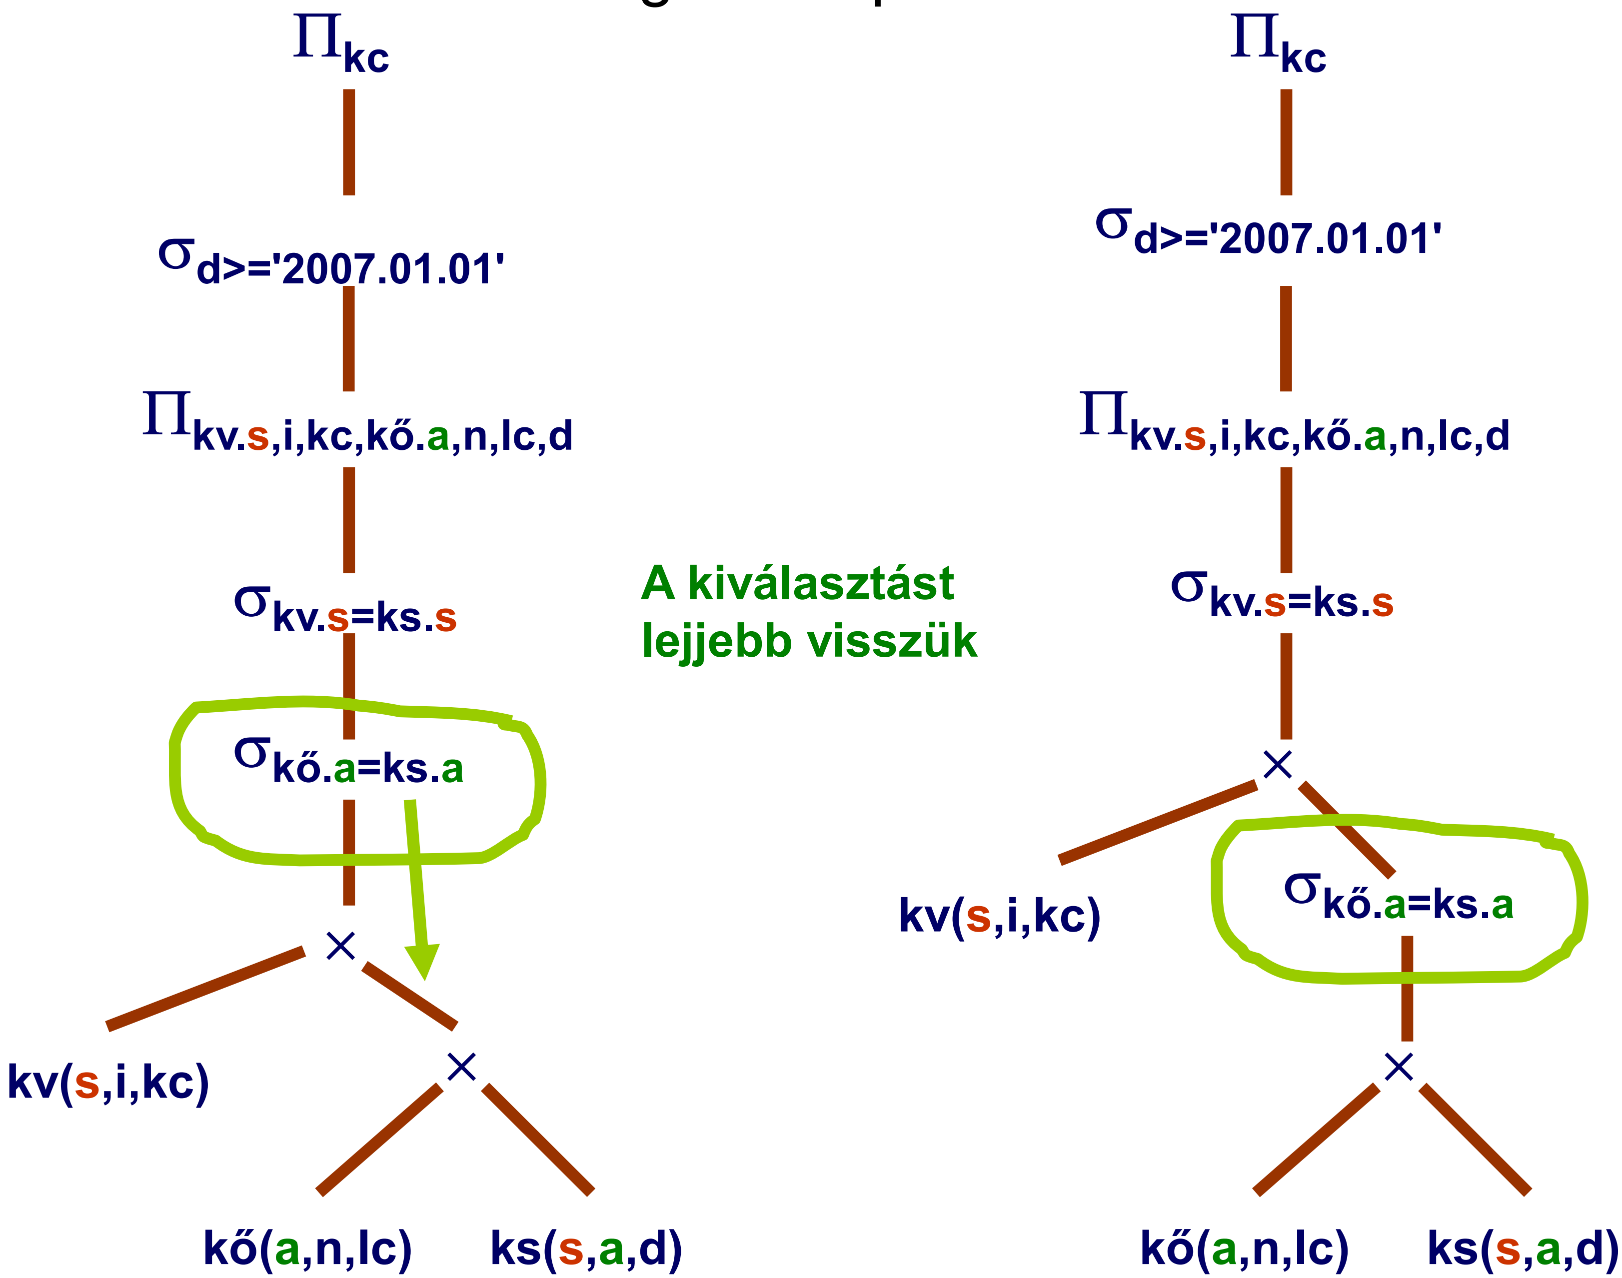

Algebrai optimalizáció

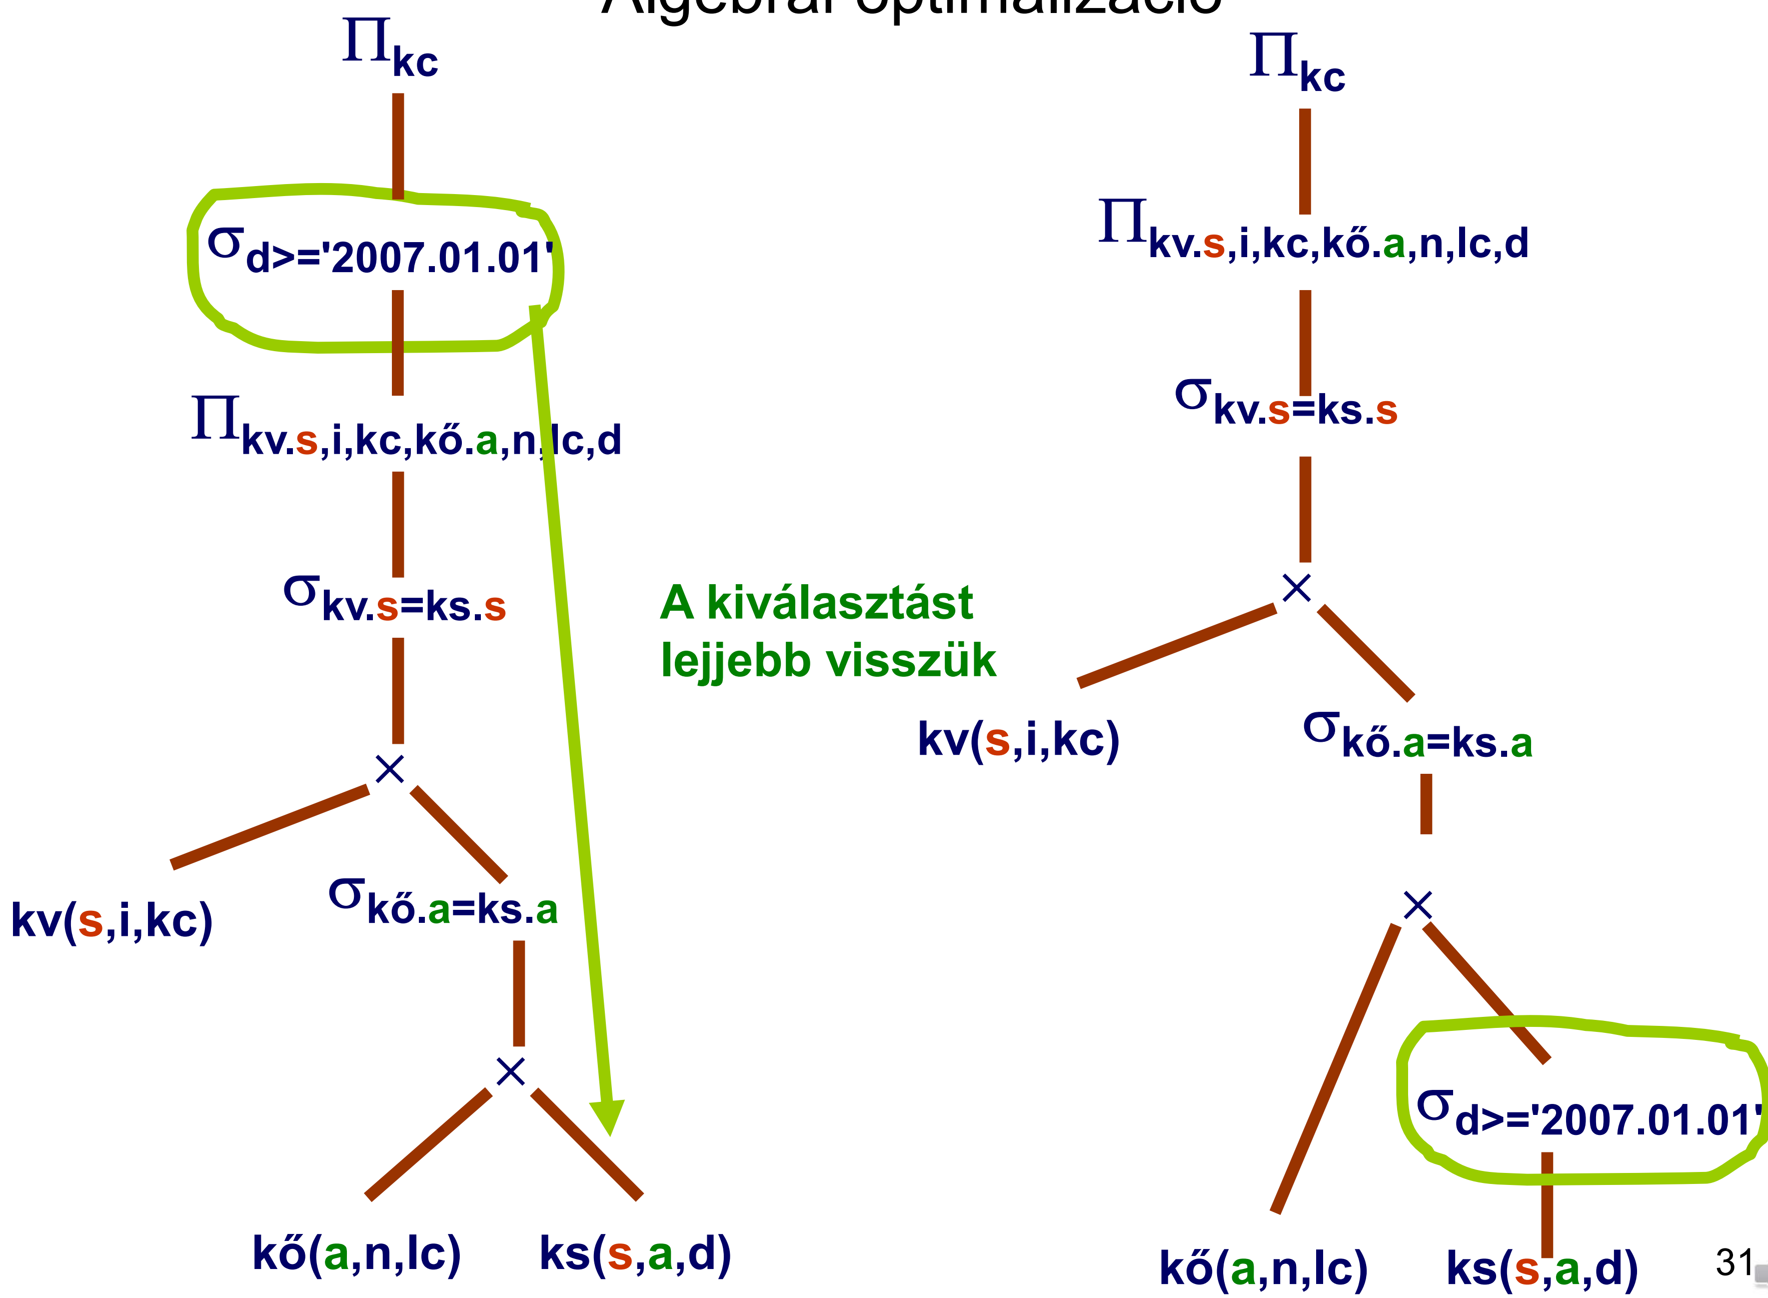

A kiválasztást lejjebb visszük

Algebrai optimalizáció

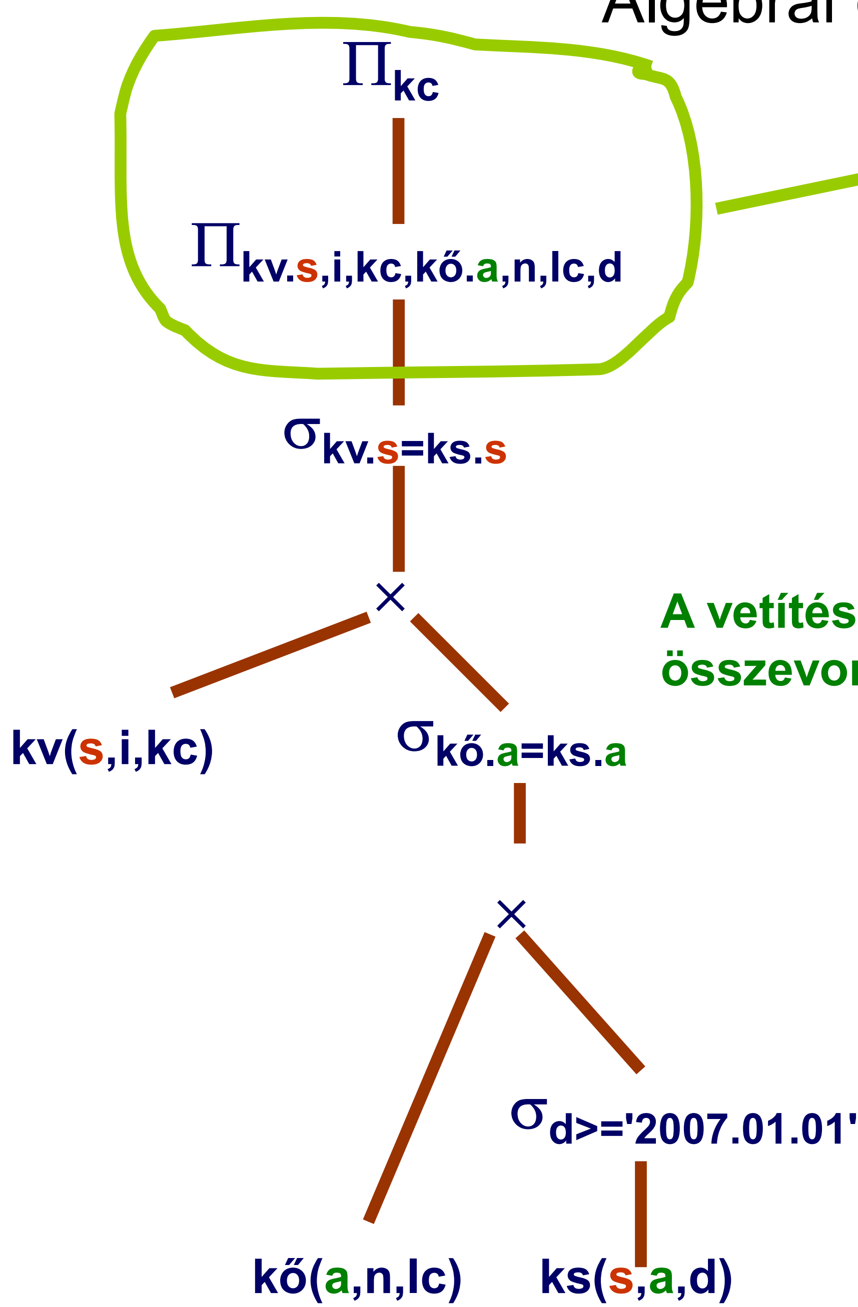

A vetítéseket összevonjuk

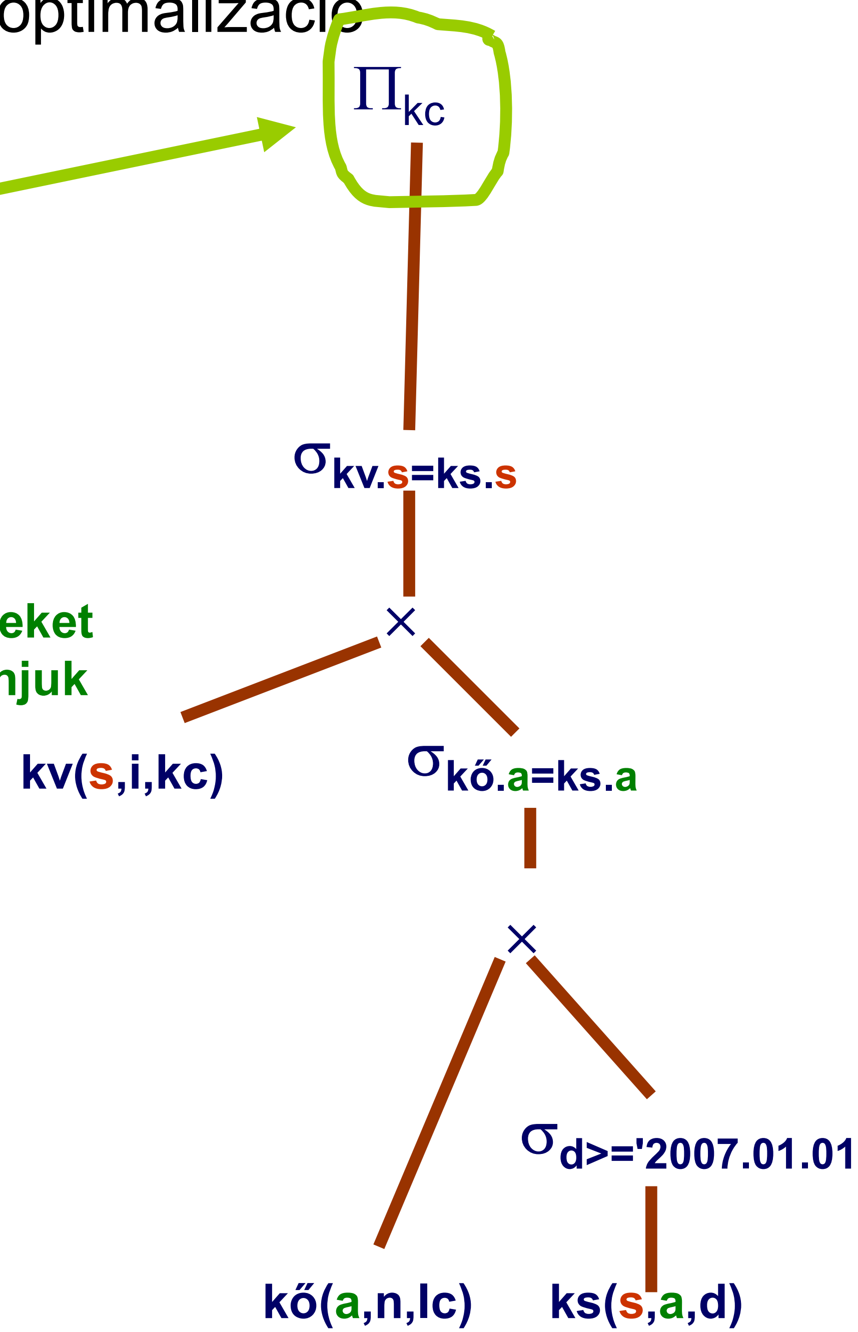

Algebrai optimalizáció

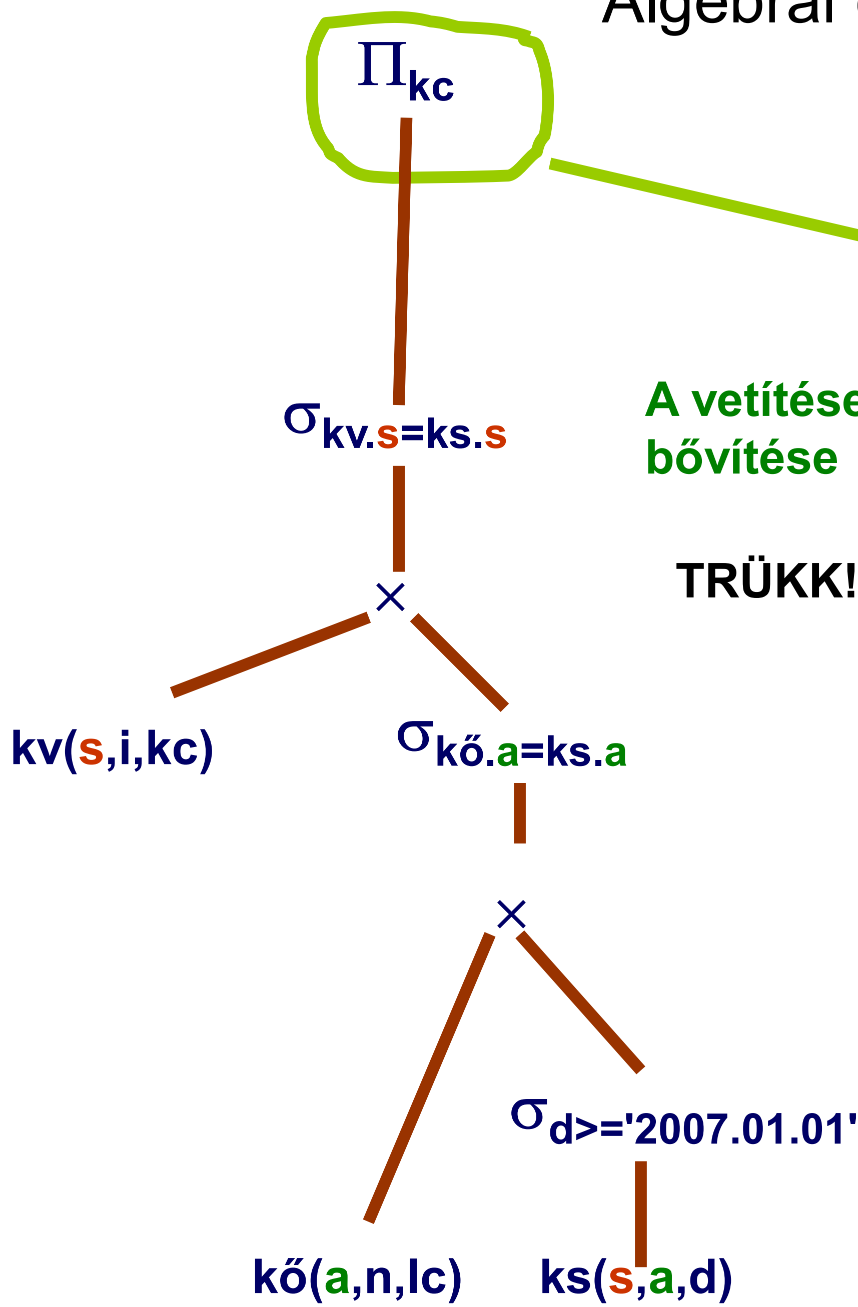

A vetítések bővítése

TRÜKK!

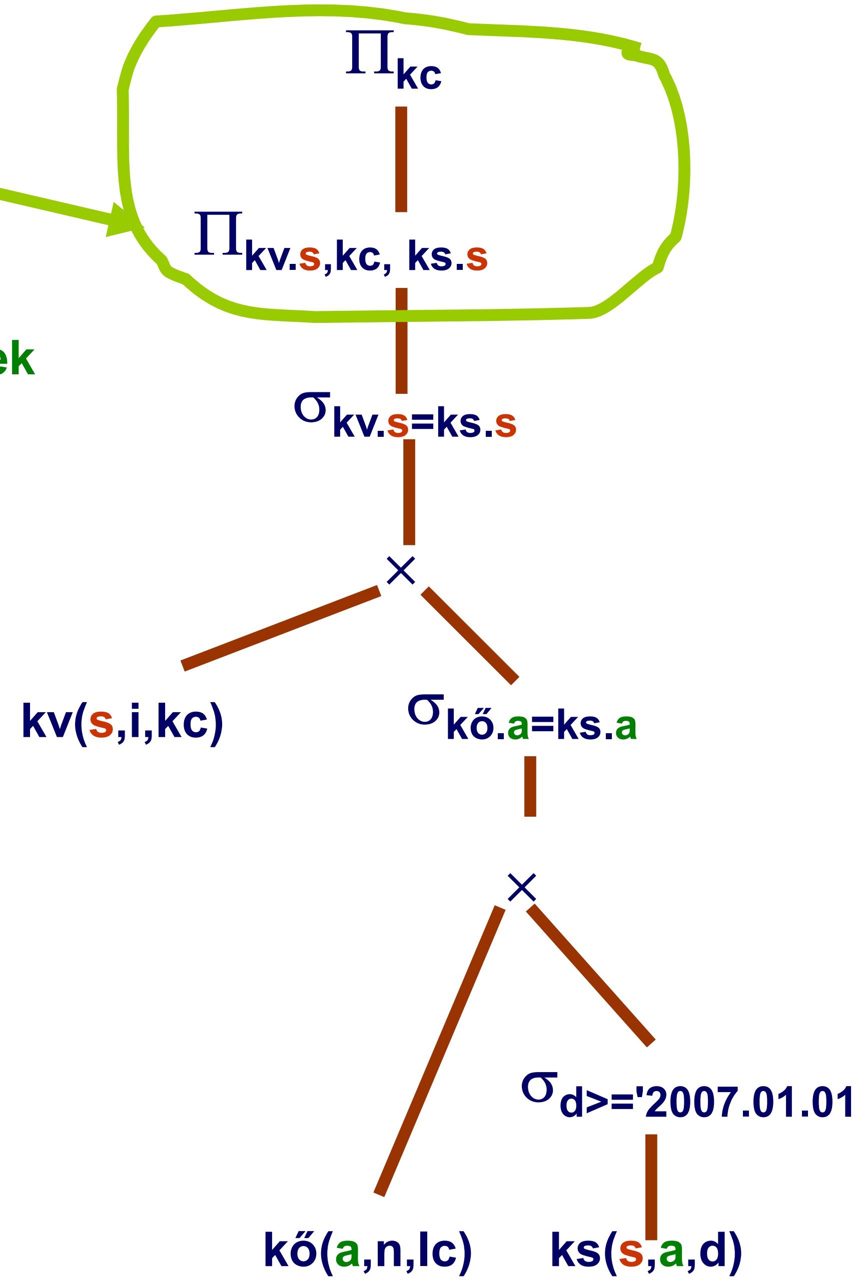

Algebrai optimalizáció

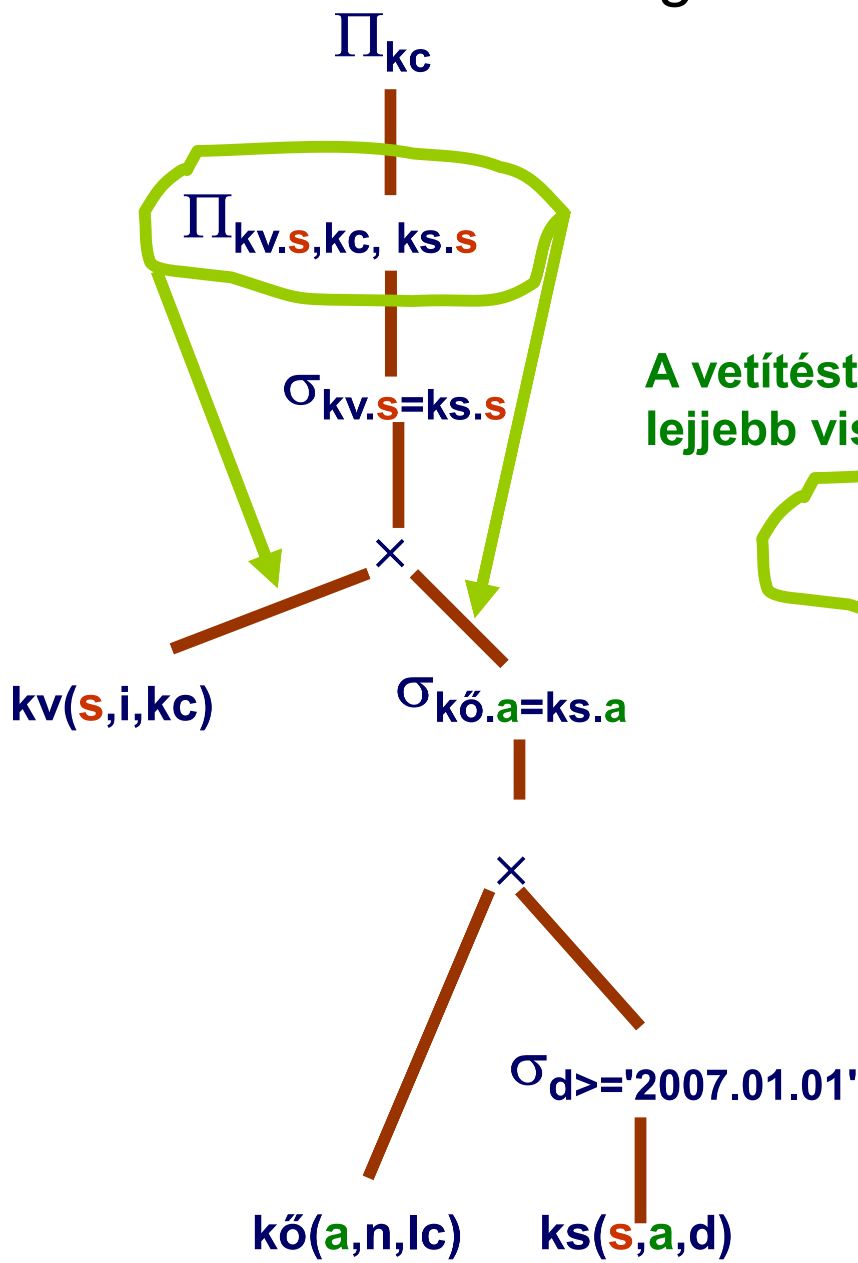

A vetítést lejjebb visszük

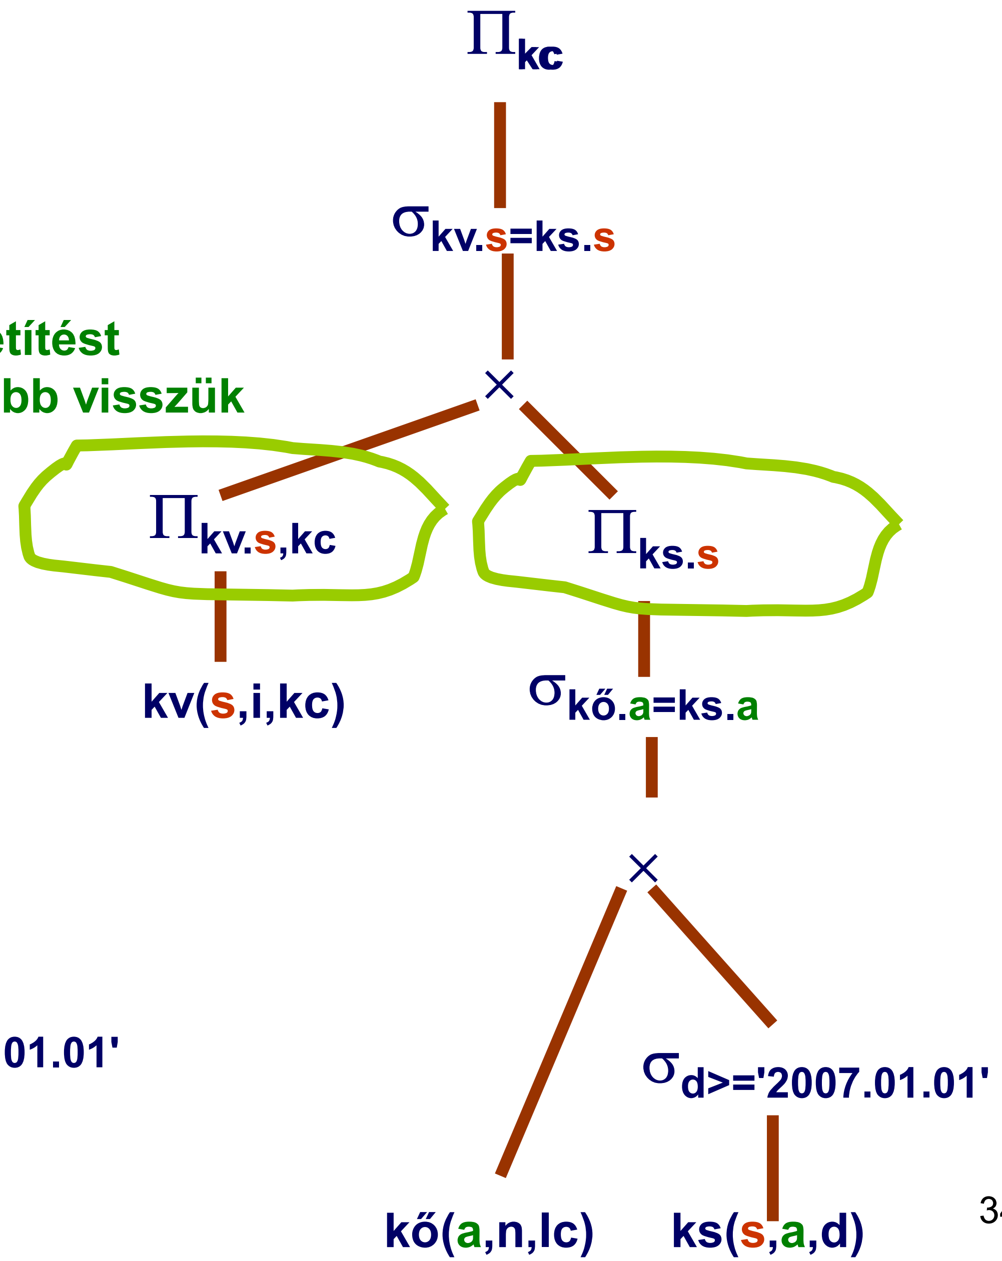

Algebrai optimalizáció

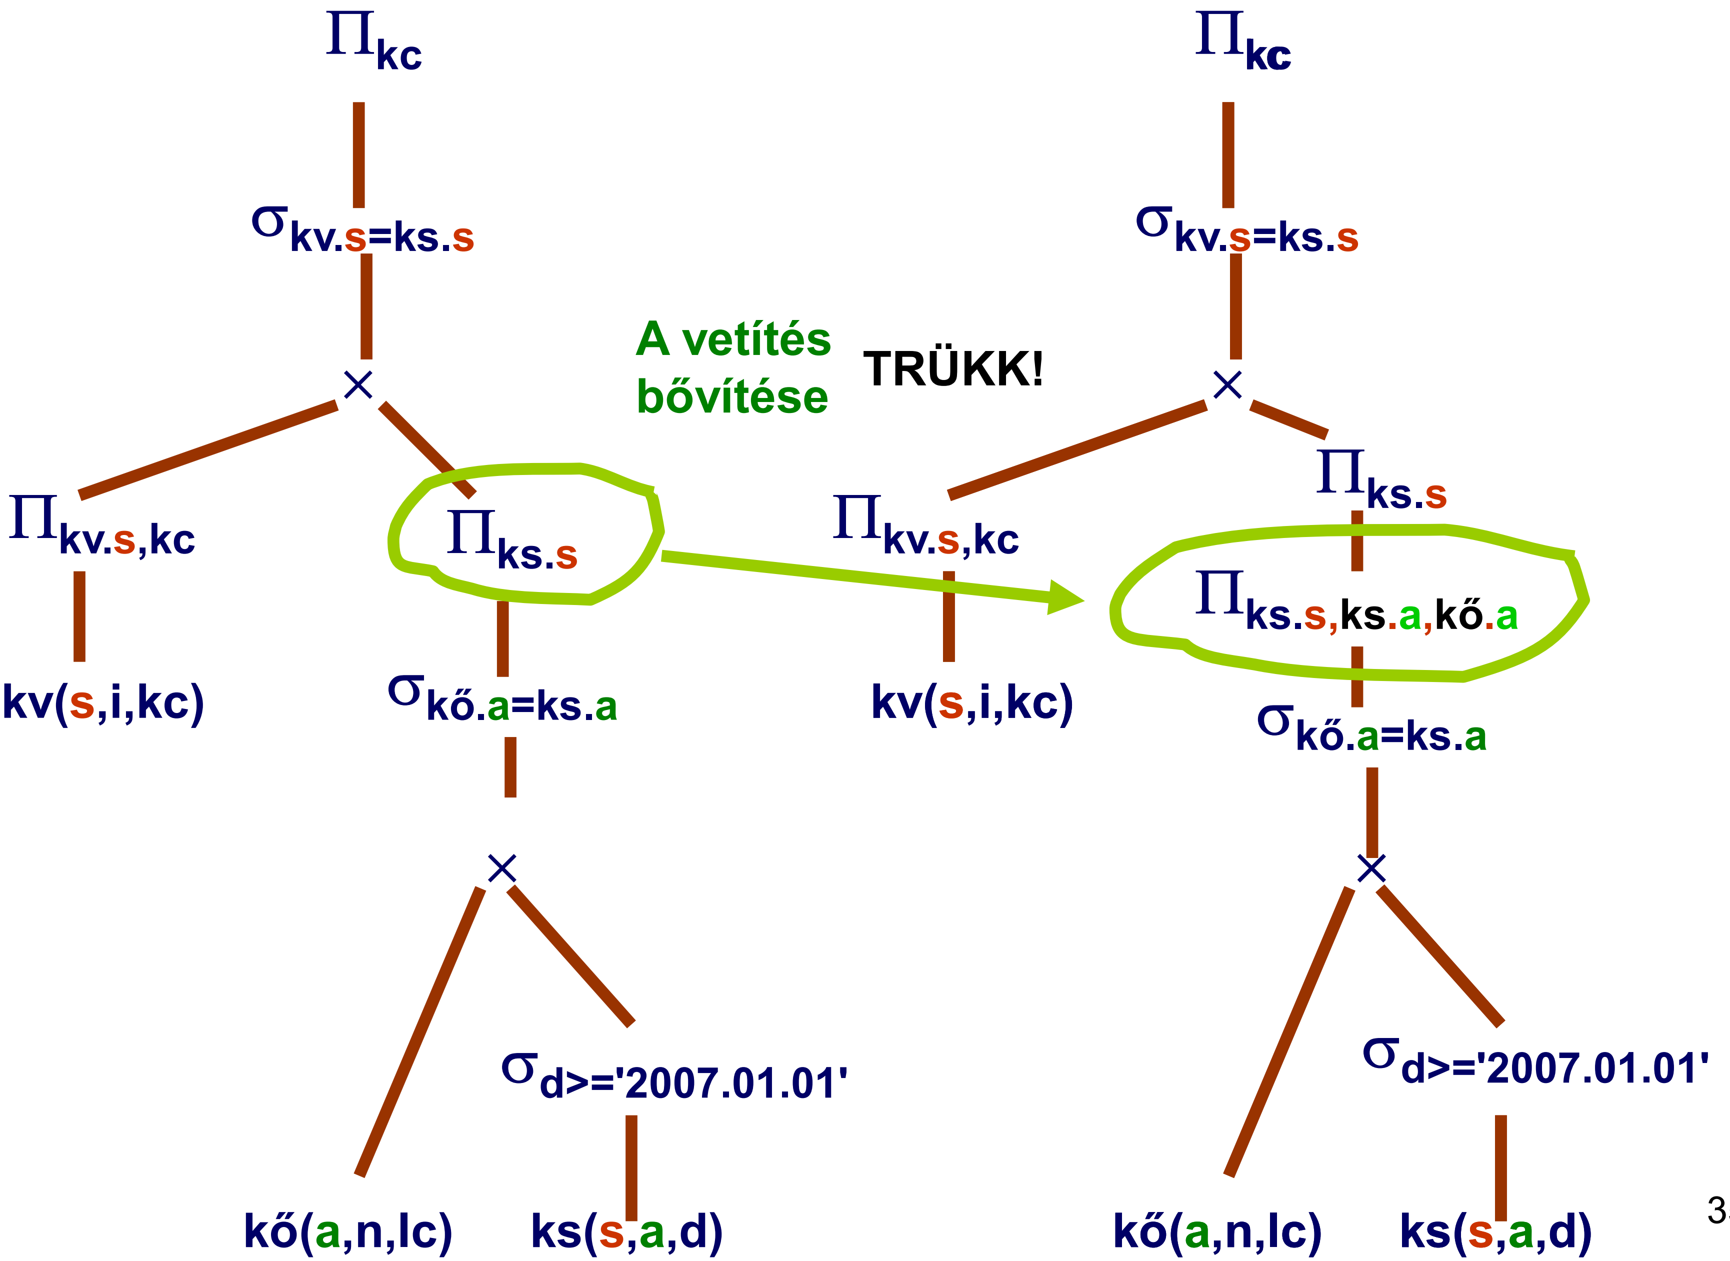

Algebrai optimalizáció

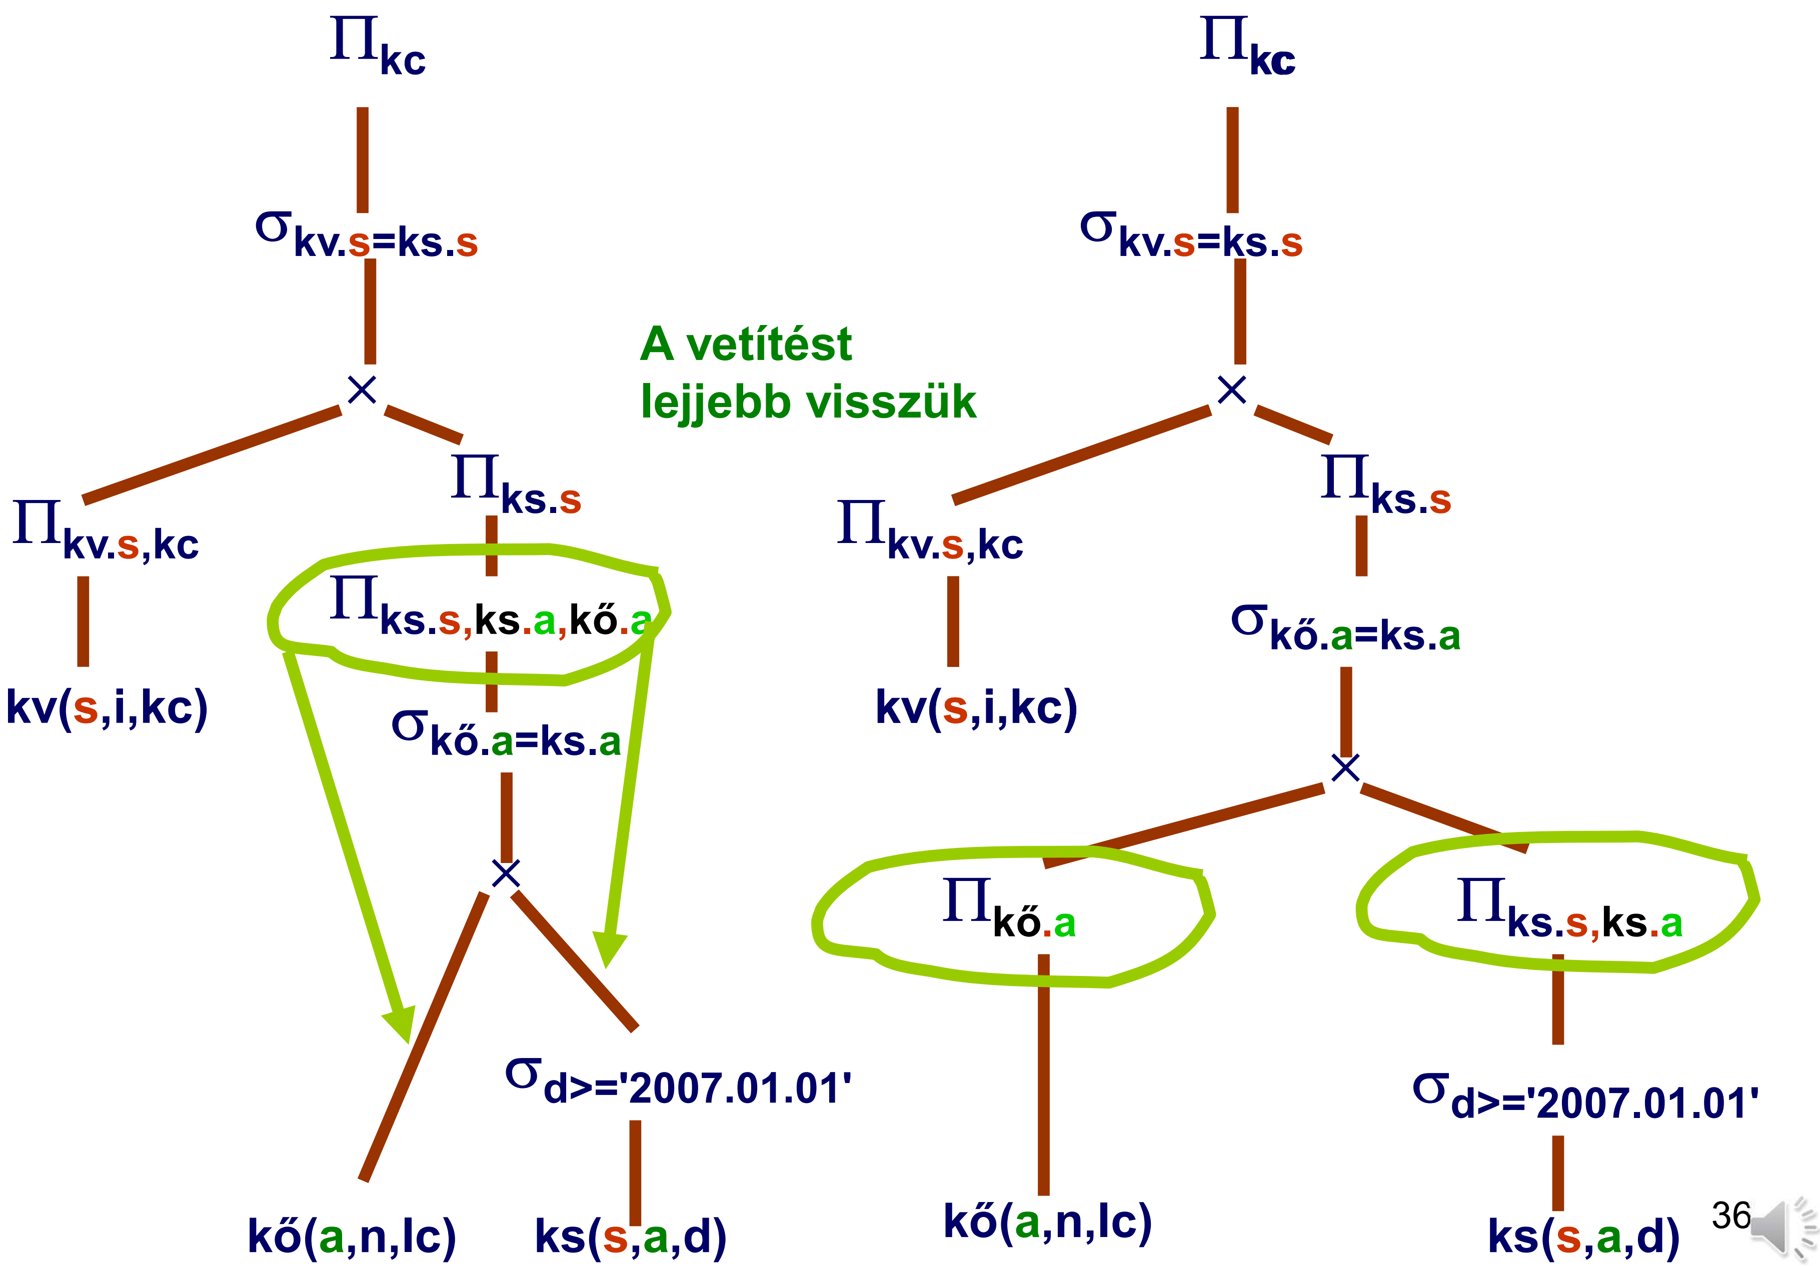

Algebrai optimalizáció

Részgráfokat képezünk (az equi-join miatt a levelekig kiegészítjük a csoportokat)

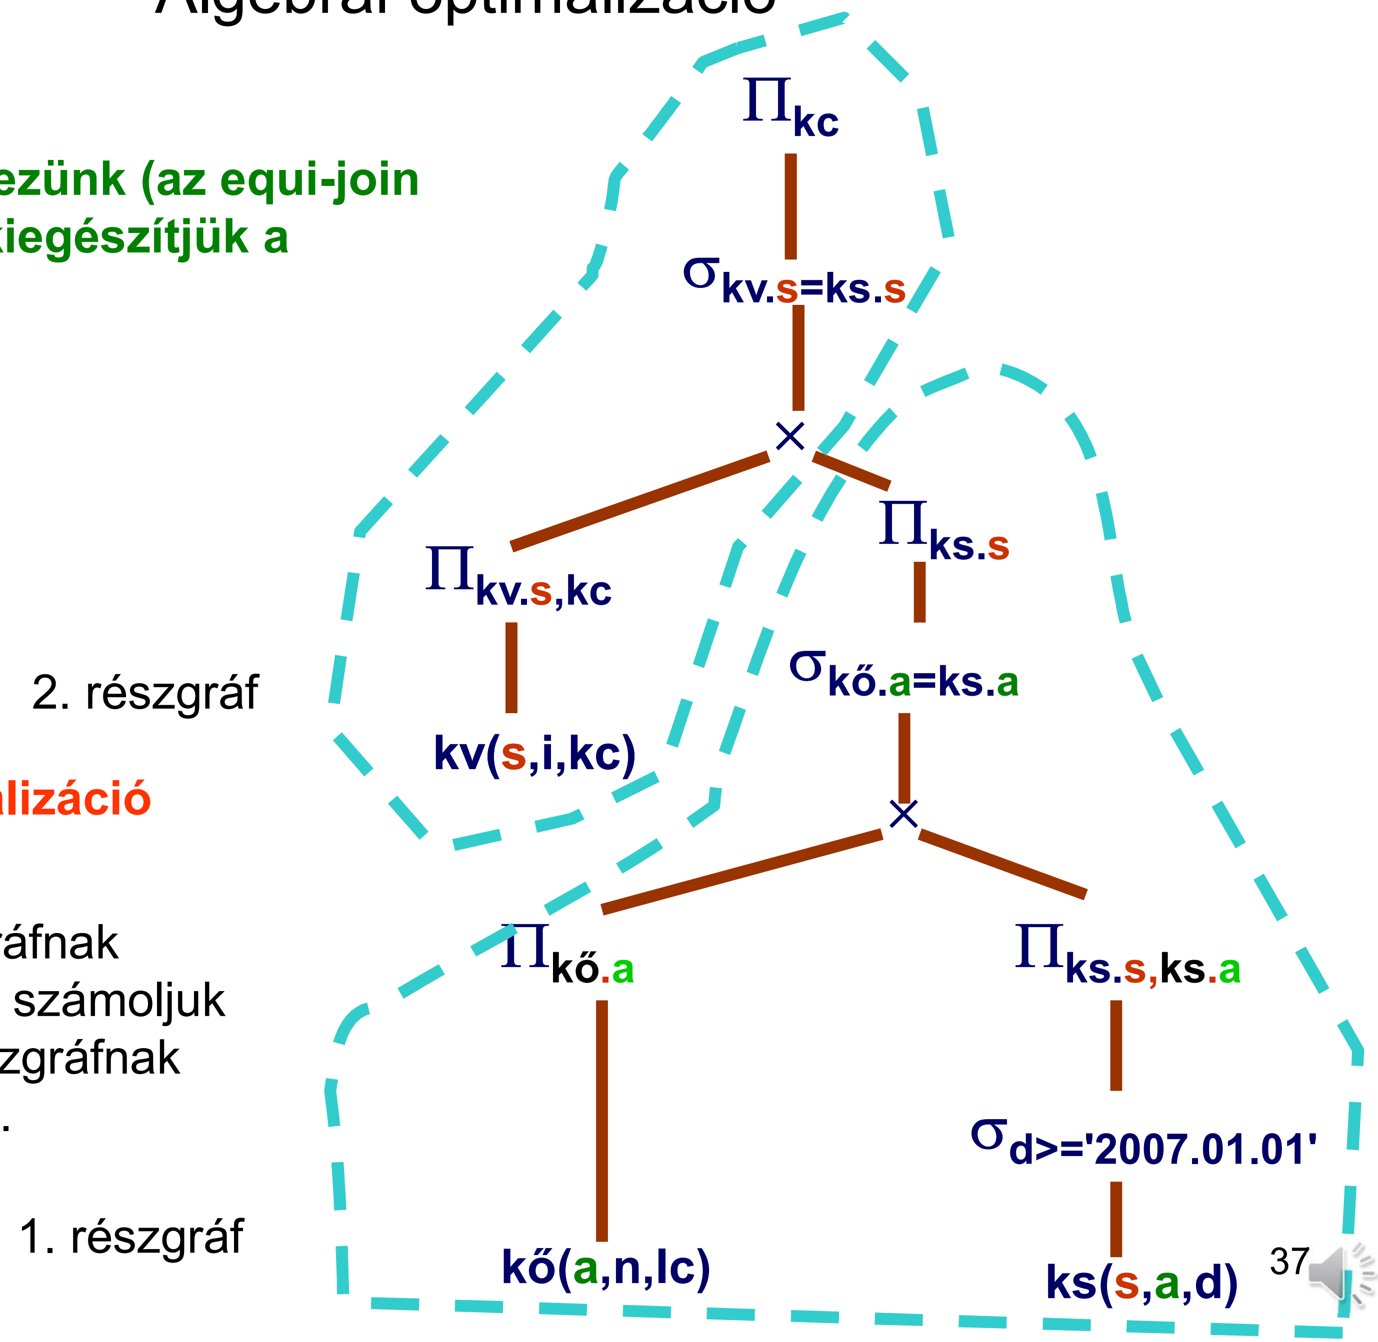

Az algebrai optimalizáció eredménye:

Először az 1. részgráfnak megfelelő kifejezést számoljuk ki, és utána a 2. részgráfnak megfelelő kifejezést.

Köszönöm a figyelmet!